

Afet Yönetiminde Data-Centric AI: LLM Tabanlı Stacking ve Pseudo-Label Üretimi ile Ölçeklenebilir Named Entity Recognition

Abstract

Bu çalışma, morfolojik açıdan zengin ve sondan eklemeli dillerin dilsel zorluklarını ele alırken, Türkçe afet temalı sosyal medya metinlerinden otomatik bilgi çıkarımını mümkün kılmayı amaçlayan, Named Entity Recognition (NER) görevi için yüksek performanslı ve ölçeklenebilir bir ‘Teacher-Student’ mimarisi sunmaktadır. Çalışma, veri etiketleme maliyetlerini azaltmak amacıyla üç Large Language Model’in (LLM) (Gemini 2.5 Pro, Claude Sonnet 4.5, GPT-5) kolektif zekasını birleştiren bir ‘Stacking’ yaklaşımı benimsemektedir. 500 cümlelik ‘Gold Standard’ veri kümesi üzerinde yürütülen deneylerde, Gemini 2.5 Pro modeli 0.9245 Macro F1-Score ile en yüksek bireysel performansı gösterirken, önerilen Stacking yöntemi 0.9313 Macro F1 skoruna ulaşarak (sızıntısız tweet düzeyi GroupKFold altında 0.9219) en başarılı ‘Teacher’ modeli olarak belirlenmiştir. Bu maliyetli modelin bilgisi, Teacher’ın ayrık tahminlerinin Student için eğitim hedefi olarak kullanıldığı hard-label ‘Pseudo-Labeling’ yoluyla daha verimli BERT tabanlı ‘Student’ modellerine aktarılmıştır. Sonuçlar, 3.000 veriyle eğitilen student modellerin 5-Fold Cross-Validation altında 0.9133’e varan Macro F1 skorlarına ulaştığını ve sınırlı gold veriyle eğitilen temel modele (Macro F1=0.8335) kıyasla daha yüksek genelleme yeteneği sergilediğini göstermiştir. Toplam 17.000 pseudo-labeled örneğe ölçeklendiğinde, nihai model (Stacked-BERT-17k) 300 cümlelik kör test kümesinde 0.9160 Macro F1 skoru elde ederek, önerilen metodolojinin verinin kıt olduğu kriz dönemlerinde insani ihtiyaçların hızla haritalanmasını ve lojistik yönlendirmeyi mümkün kılan etkili bir çözüm olduğunu kanıtlamıştır.

Keywords: Large Language Models (LLM), Ensemble Learning, Stacking, Pseudo-Labeling, Symbolic Knowledge Distillation, Named Entity Recognition (NER), Türkçe NLP

1. Giriş

Afet yönetimi süreçlerinde zaman kritik bir faktördür ve kriz anlarında sosyal medya platformları, sahadan gerçek zamanlı bilgi toplayan devasa bir veri akışı sağlamaktadır (enkaz altından gelen çağrılar, lojistik ihtiyaçlar, hasar durumu vb.). Özellikle 6 Şubat 2023 tarihinde Türkiye ve Suriye’yi etkileyen depremler, bu platformların hayati önemini bir kez daha ortaya koymuştur. Ancak bu büyük veri kümelerinin insan gücüyle manuel olarak işlenmesi imkânsızdır ve afet sırasında hızlı aksiyon alınabilmesi için otomatik bilgi çıkarım sistemlerine, özellikle Named Entity Recognition (NER) modellerine ihtiyaç duyulmaktadır. Bu bağlamda NER modelleri, sosyal medyadan akan yapılandırılmamış metin akışlarını ‘Kim?’ (enkaz altındaki veya kayıp kişiler), ‘Nerede?’ (mahalle, sokak, bina bilgisi) ve ‘Ne gerekiyor?’ (vinç, çadır, gıda) gibi yapılandırılmış ve haritalanabilir veri noktalarına dönüştürmektedir. Bu çalışmanın temel amacı, arama kurtarma ekiplerini en uygun ekipmanla doğru konuma yönlendiren bu kritik bilginin, manuel taramanın neden olduğu zaman kaybı olmaksızın otonom olarak çıkarılmasını sağlamaktır. Geleneksel derin öğrenme tabanlı NER modelleri (ör. BERT), yüksek performans için binlerce etiketli veriye ihtiyaç duymaktadır. Ancak kriz zamanlarında uzmanlar tarafından hazırlanmış büyük ölçekli etiketli veri kümeleri (‘Gold Standard’) mevcut değildir. Son yıllarda Large Language Model’ler (LLM), few-shot öğrenme yetenekleri sayesinde bu veri kıtlığı problemine güçlü bir alternatif sunmaktadır. Bununla birlikte, LLM’lerin üretim ortamlarında doğrudan kullanımı; yüksek inference maliyetleri, Application Programming Interface (API) gecikmesi ve veri gizliliği endişeleri nedeniyle ölçeklenebilir değildir.

Bu sınırlamaların üstesinden gelmek için ortaya çıkan etkili bir paradigma, büyük modellerin bilgilerini daha hafif ve hızlı ağlara aktarmak üzere kullanıldığı ‘Teacher-Student’ çerçevesidir. Hu et al. [1] tarafından belirtildiği üzere, bu mimariler bilgi sıkıştırma ve adaptasyon sağlayarak devasa modellerden daha hafif ve hızlı ağlara bilgi aktarımını mümkün kılmaktadır. Liu et al. [2], ‘EvoKD’ çalışmalarıyla LLM’lerin bilgisinin daha küçük modellere aktarılmasının NER gibi karmaşık NLP görevlerinde yüksek performans elde edebileceğini göstermiştir. Benzer şekilde Xia et al. [3], LLM’lerin veri etiketlemede ‘candidate identifier’ olarak kullanıldığı ve bu bilginin ardından daha küçük modellere aktarıldığı çerçevelerin hem veri kalitesini artırdığını hem de insan emeği maliyetlerini düşürdüğünü vurgulamaktadır.

Bu çalışma, afet verisi işlemede karşılaşılan etiketli veri kıtlığı ve hesaplama

maliyeti sorunlarını ele almak amacıyla LLM tabanlı Stacking ve pseudo-label üretimini birleştiren hibrit bir yaklaşım önermektedir. Yaklaşımımız, tek bir LLM'ye güvenmek yerine üç farklı modelin (Gemini 2.5 Pro, Claude Sonnet 4.5, GPT-5) 'kolektif zekasını' kullanan bir ensemble stratejisine dayanmaktadır. Zhao et al. [4], çok aşamalı işbirlikçi bilgi aktarım yöntemlerinin yarı denetimli görevlerde model performansını artırdığını belirtmektedir; benzer bir motivasyonla çalışmamızda bireysel LLM hatalarını en aza indirmek için bir Stacking mekanizması (Model B) geliştirilmiştir.

Önerilen metodoloji kapsamında, yalnızca 500 cümlelik küçük bir 'Gold Standard' veri kümesi kullanılarak önce LLM'lerin (Teacher'lar) rehberliğinde yüksek kaliteli 3.000 tweet'lik bir 'Silver Standard' veri kümesi oluşturulmuş, ardından Pseudo-Labeling yoluyla 17.000 tweet'lik bir 'Scaled' veri kümesi otomatik olarak üretilmiştir. Deneylerimiz, Stacking yöntemiyle elde edilen teacher modelin 0.9313 Macro F1 skoruna ulaştığını, Teacher tarafından üretilen pseudo-label'lar ile eğitilen nihai student modelin (Stacked-BERT-17k) ise daha önce görülmemiş bir kör test kümesinde 0.9160 Macro F1 skoruyla yüksek genelleme yeteneği sergilediğini göstermektedir. Bu sonuçlar, Liu et al. [2] tarafından önerilen 'Learning with Less' ilkesini doğrulamakta ve kriz zamanlarında hızlı, düşük maliyetli ve yüksek doğruluklu modellerin geliştirilebileceğini göstermektedir.

2. İlgili Çalışmalar

Named Entity Recognition (NER), bilgi çıkarım süreçlerinin temel taşı olmakla birlikte, özellikle düşük kaynaklı dillerde ve gerçek zamanlı veri akışının kritik olduğu afet yönetimi gibi alanlarda veri kıtlığı nedeniyle zorlu bir problem olmaya devam etmektedir. Bu bölüm, literatürdeki mevcut yaklaşımları üç ana başlık altında incelemektedir: LLM tabanlı bilgi aktarımı ve pseudo-labeling, ensemble öğrenme stratejileri ve Türkçe/alana özgü çalışmalar; ayrıca önerilen metodolojinin bu yaklaşımlara kıyasla avantajlarını tartışmaktadır.

2.1. LLM Tabanlı Bilgi Aktarımı ve Pseudo-Labeling

Large Language Model'ler (LLM), az sayıda örnekten öğrenme yetenekleri sayesinde veri etiketleme süreçlerinde devrim yaratmıştır. Ancak bu modellerin yüksek inference maliyetleri ve operasyonel hantallığı, klasik soft-target Knowledge Distillation'dan [5], Teacher'ın ayrık tahminlerinin doğru-dan denetim sinyali olarak kullanıldığı pseudo-labeling ve Symbolic Knowl-

edge Distillation [6] gibi hard-label varyantlara uzanan çeşitli bilgi aktarım yaklaşımlarını motive etmiştir.

Saxena et al. [7], kriz yönetimi senaryolarında etiketli veri ihtiyacını ortadan kaldırmak amacıyla geliştirdikleri çalışmada, LLM bilgisini adapter’lar aracılığıyla daha küçük modellere aktaran bir çerçeve sunmuştur. Benzer bir yaklaşımla Deußer et al. [8], GPT-4 gibi modellerden üretilen sentetik verilerle eğitilen küçük encoder modellerin, manuel etiketlemeye gerek kalmadan kişisel verilerin anonimleştirilmesinde yüksek başarı elde ettiğini göstermiştir. Ayrıca Li et al. [9], çalışmalarında LLM’lerin yapılandırılmış çıktı üretme yeteneklerini optimize ederek bilgi çıkarımını iyileştirmiştir. Lin et al. [10], çalışmalarında tek tip student modeller yerine farklı mimarilere sahip heterojen student modeller (LSTM, CNN vb.) kullanarak bilgi aktarımını zenginleştirmiştir. Xiao et al. [11], makalelerinde birden fazla küçük parametrelili LLM’in (GLM-4-9B, Phi-4, Qwen-2.5-14B) çıktılarının birleştirilmesinin, tek bir devasa model kullanmaya kıyasla maliyet-etkin bir çözüm olduğunu göstermiştir. Mevcut literatür (ör. ANON ve EL4NER) tipik olarak tek bir ‘Teacher’ modelin veya küçük LLM’lerden oluşan bir topluluğun bilgisine dayanırken; çalışmamız, üç farklı state-of-the-art (SOTA) modelin Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5 kolektif zekasını ‘Stacking Ensemble’ yöntemiyle birleştiren bir ‘Super Teacher’ oluşturmasıyla farklılaşmaktadır.

2.2. Düşük Kaynaklı NER için Ensemble Öğrenme Stratejileri

Etiketli verinin kıt olduğu dillerde veya alanlarda, model dayanıklılığını artırmak için ensemble öğrenme stratejileri yaygın olarak kullanılmaktadır. Dilden bağımsız NER sistemlerinin temellerini atan çalışmadan bu yana, farklı modellerin güçlü yönlerini birleştirme fikri önemini korumaktadır [12]. Özellikle düşük kaynaklı bir dil senaryosu olarak Hintçe üzerine yapılan çalışmada, birden fazla makine öğrenmesi modelinin voting yoluyla birleştirilmesinin bireysel modellerin hatalarını düzelterek F1 skorunu iyileştirdiği bildirilmiştir [13]. Literatürdeki topluluk öğrenmesi çalışmaları (ör. Hintçe NER) genellikle sonucu ‘Inference’ aşamasında birden fazla model çalıştırarak bulmayı amaçlamaktadır. Bu durum canlı sistemlerde (deprem anı gibi) gecikmeye neden olmaktadır. Çalışmamızda ise ensemble öğrenme (stacking) yalnızca eğitim verisi üretim aşamasında kullanılmıştır. Canlı sistemde, bu bilgiyle eğitilmiş tek bir BERT modeli (Student) çalışmakta ve ensemble modellerin yüksek doğruluğunun ‘tek model’ hızında sunulması mümkün olmaktadır.

2.3. Türkçe ve Alana Özgü NER Çalışmaları

Türkçe, sondan eklemeli yapısı nedeniyle NER çalışmaları için kendine özgü zorluklar barındırmaktadır. Çetindağ et al. [14], çalışmalarında hukuk alanı için özel olarak etiketlenmiş bir veri kümesi oluşturmuş ve BiLSTM-CRF mimarisıyla %92.27 F1 skoru elde ederek genel amaçlı modellerin spesifik alanlarda yetersiz kaldığını kanıtlamıştır.

Benzer şekilde Khudoyberdieva and Diri [15], Türkçe için 23 farklı alt kategoriye kapsayan fine-grained modeller geliştirmiş; genel varlık tespitinde %93.34, alt kategorilerde ise %79.82 F1 skoru başarı elde etmiştir. Sağlık alanında Akcali et al. [16], Türkçe mamografi raporlarından bilgi çıkarımı için prompt engineering ile Large Language Model’lerin (LLM) kullanımını önermiştir. Çalışma, geniş bağlam penceresine sahip Gemini 1.5 Pro modeliyle ‘many-shot’ (çoklu örnek) öğrenme yaklaşımını benimsemiş ve 165 örnek içeren kapsamlı bir prompt tasarlamıştır. Bu yöntemle anatomi ve izlenim gibi klinik varlıkların tespitinde 0.84 exact match F1 ve 0.99 relaxed match F1 skoru elde edilmiş, sınırlı NLP kaynaklarına sahip dillerde bile yüksek performansa ulaşılabileceği gösterilmiştir. TMD-NER [17] gibi sosyal medya metinlerinde varlık ismi tanıma üzerine yapılan güncel çalışmalar, 121.310 cümlelik büyük bir veri kümesi ve kural tabanlı modüllerle desteklenen BiLSTM-CRF mimarisi kullanarak %84 F1 skoru elde etmiştir. Bu çalışma yüksek performans sunsa da, arama kurtarma için kritik olan akut bir krizin ilk 72 saatinde 121.310 verinin toplanması ve manuel olarak etiketlenmesi operasyonel açıdan imkânsızdır. Dolayısıyla bu manuel kürasyon darboğazının aşılması yalnızca algoritmik bir iyileştirme değil, gerçek zamanlı afet müdahalesi için mutlak bir zorunluluktur. Önerdiğimiz LLM tabanlı Data-Centric yaklaşım, yalnızca 500 manuel etiketli veriyle daha yüksek bir başarı düzeyi elde ederek bu kritik boşluğu doldurmakta ve acil durumlarda gereken hızlı devreye almayı sağlamaktadır. Veri kalitesi açısından Elgold çalışması [18], titiz insan doğrulamasıyla oluşturulan ‘Gold Standard’ veri kümelerinin önemini vurgulamaktadır; ancak afet yönetimi gibi zamana duyarlı senaryolarda bu süreçler sürdürülebilir değildir. Çalışmamız, LLM’lerin ‘Stacking’ yöntemiyle ürettiği yüksek kaliteli ‘Silver Standard’ veriler sayesinde manuel kürasyona gerek kalmadan krizde gereken hız ve ölçeklenebilirliği sunarak literatürdeki bu boşluğu doldurmaktadır.

Türkçe literatürdeki mevcut çalışmalar (ör. TMD-NER, Hukuk ve Fine-grained NER), yüksek performans için binlerce verinin uzmanlar tarafından manuel olarak etiketlenmesini gerektirmektedir. Bu süreç hem maliyetli hem de yavaştır. Çalışmamız ise ‘Data-Centric Artificial Intelligence’ yaklaşımını

kullanarak yalnızca 500 manuel etiketli veriyle ('Gold Standard'), (ara aşamada 3.000 örneklik bir 'Silver Standard' üzerinden türetilen) 17.000 verilik devasa, pseudo-labeled bir 'Scaled Set'i otomatik olarak üretmeyi başarmış ve devasa manuel etiketleme hatlarına (TMD-NER gibi genel çalışmalarda kullanılan 121.310 veri gibi) verimli bir alternatif sunmuştur. LLM'lerin 'Stacking' yöntemiyle ürettiği veriler sayesinde çalışmamız, Elgold çalışmasında belirtilen manuel kürasyon darboğazıyla karşılaşmadan krizde gereken hız ve ölçeklenebilirliği sunmaktadır. Modelimiz, manuel etiketleme maliyeti olmaksızın Türkçe afet verilerinde %91.60 doğruluk (Blind Test) elde ederek ve az veriyle (few-shot'tan many-shot'a) yüksek performansı başarıyla göstererek literatürdeki diğer çalışmalardan ayrılmaktadır.

3. Materyal ve Yöntem

Bu bölüm, afet yönetimi süreçlerinde kullanılmak üzere geliştirilen veri merkezli Named Entity Recognition (NER) sisteminin mimarisini ve uygulama adımlarını detaylandırmaktadır. Önerilen metodoloji şu adımlardan oluşmaktadır: ham verinin toplanması ve işlenmesi, Large Language Model'ler (LLM) kullanılarak 'Teacher' modellerin oluşturulması, Ensemble Learning (Stacking) yoluyla veri kalitesinin en üst düzeye çıkarılması ve son olarak bu bilginin hard-label pseudo-labeling ile düşük hesaplama maliyetli 'Student' modellere (BERT vb.) aktarılması. Ayrıca bu bölümde, veri kümesinin güvenilirlik düzeylerine göre 'Gold', 'Silver' ve 'Scaled' (Pseudo-labeled) olarak sınıflandırılma süreci ile model performansını ölçmek için kullanılan değerlendirme metrikleri sunulmaktadır.

3.1. Veri Kümesinin Hazırlanması ve Sınıflandırılması

Çalışmanın deneysel çerçevesini oluşturmak amacıyla, 6 Şubat Kahramanmaraş depremlerinin hemen ardından 7-15 Şubat 2023 tarihleri arasında Twitter (X) platformundan web scraping teknikleriyle sistematik olarak ham tweet'ler toplanmıştır. Veri toplama sürecinde "deprem", "enkaz", "yardım", "acil" gibi Türkçe anahtar kelimeler ve en çok etkilenen on ilin (Kahramanmaraş, Hatay, Adıyaman, Gaziantep, Malatya, Osmaniye, Diyarbakır, Şanlıurfa, Kilis, Adana) coğrafi tanımlayıcıları aracılığıyla afete özgü içerikler hedeflenmiştir. Veri toplamadan sonra, birebir kopyaları, yakın kopyaları ve retweet'leri elemek için titiz bir deduplication süreci uygulanmıştır.

'Data-Centric Artificial Intelligence' yaklaşımı benimsenerek, derlenen bu ham veri havuzu, modelin eğitim, doğrulama ve test aşamaları için Tablo 1'de

özetlendiği üzere birbirini dışlayan dört ana kategoriye ayrılarak işlenmiştir. Bu veri hiyerarşisinin ve genel sürecin şematik gösterimi Şekil 1’de sunulmaktadır.




Figure 1: Deprem Tweet’leri için Veri Merkezli Bir NER Modeli Oluşturma Adımları

Şekil 1’de özetlendiği üzere, veri havuzu üretim yöntemine (manuel veya otomatik) ve güvenilirlik düzeyine göre üç ana kategoriye ayrılarak kullanılmıştır:

Gold Standard Eğitim Kümesi: Ham veri havuzundan rastgele seçilen 500 tweet, alan uzmanları tarafından titizlikle manuel olarak etiketlenmiştir. Etiketleme süreci, yüksek etiketleyiciler arası uyum (Cohen’s Kappa > 0.85) sağlamak amacıyla iki bağımsız etiketleyici ve ardından bir uzlaşma aşamasını içermiştir. Bu sayı derin öğrenme modelleri için düşük görünse de, bu kümenin temel amacı model eğitimi değil kalibrasyondur. Bu küme, LLM (‘Teacher’) modellerin performansını ölçmek, hatalarını analiz etmek ve önerilen Stacking (Topluluk) mekanizmasının ağırlıklarını optimize etmek için bir ‘referans noktası’ (Ground Truth) olarak kullanılmıştır.

Silver ve Scaled Veri Kümeleri: Manuel etiketlemenin yüksek maliyeti ve kriz sırasındaki zaman kısıtları nedeniyle, büyük ölçekli eğitim verisi ihtiyacı ‘Teacher’ modeller tarafından karşılanmıştır. Havuzdan seçilen 3.000 tweet, Stacking yöntemiyle otomatik olarak etiketlenerek ‘Silver Standard’ kümesi oluşturulmuştur. Bu kümenin amacı, sınırlı Gold verinin yetersiz kaldığı durumlarda BERT tabanlı ‘Student’ modellerin yüksek doğrulukla eğitilmesi için gereken yoğun veriyi sağlamaktır. Ardından, student model kalan 17.000 etiketsiz veriyi etiketlemek için kullanılmış ve nihai eğitim aşı-

ması için 17.000 örneklilik özel bir ‘**Pseudo-labeled Scaled Set**’ oluşturulmuştur.

Kör Test Kümesi (Blind Test Set): Modelin eğitim veya optimizasyon sırasında veriyi ‘ezberlemesini’ (overfitting) önlemek ve gerçek dünya performansını ölçmek amacıyla 300 tweet’lik izole bir küme ayrılmıştır. Bu küme eğitim sürecinde hiçbir zaman kullanılmamış (ne Stacking’de ne de Student model eğitiminde), böylece modelin daha önce hiç görmediği veriler üzerindeki genelleme yeteneğinin tarafsız olarak raporlanması sağlanmıştır.

Table 1: Veri Kümesi Bölümlerinin Dağılımı ve Özellikleri

Veri Bölümü	Kümesi	Etiketleme Yöntemi	Boyut (Tweet)	Temel Amaç
Gold Standard		Manuel (Uzman)	500	LLM Teacher kalibrasyonu
Silver Standard		Otomatik (LLM Stacking)	3,000	Student için pseudo-label eğitimi
Scaled Set		Otomatik (Pseudo-labeling)	17,000	Nihai model ölçekleme
Blind Test Set		Manuel (Uzman)	300	Tarafsız nihai değerlendirme
Toplam Veri			20,800	

Tablo 1’de gösterilen genel dağılımın ötesinde, Tablo 2, Gold Standard veri kümesinin dilsel ve varlık düzeyindeki özelliklerinin ayrıntılı bir dökümünü sunmaktadır. Görüldüğü üzere veri kümesi, kullanıcıların yardımın ‘nerede’ gerektiğini paylaşmaya öncelik verdiği afet tweet’lerinin aciliyetini yansıtacak şekilde yüksek yoğunlukta konum tabanlı varlık içermektedir (LOC: tüm varlıkların %52.6’sı). Derlem, yalnızca 500 tweet içinde 5.190 benzersiz token’lık çeşitli bir kelime dağarcığına sahiptir; bu da kriz sırasında kullanılan sosyal medya dilinin yapılandırılmamış ve gürültülü doğasına işaret etmektedir. Ayrıca tweet’lerin %90.2’si birden fazla varlık içermekte olup, bu durum bilgi çıkarım görevinin karmaşıklığını doğrulamakta ve LLM’ler gibi bağlam farkındalıklı modellere olan ihtiyacı gerektirmektedir. Ayrıca BIO etiketleme şeması her varlık token’ına tek ve birbirini dışlayan bir sınıf atadığından, örtüşen etiket bulunmamakta ve bu altı varlık türünün dağılımı tam olarak %100.0’a ulaşmaktadır.

Table 2: Gold Standard Veri Kümesinin Kapsamlı İstatistikleri (500 Tweet)

Metrik	Değer
Derlem İstatistikleri	
Toplam Tweet	500
Toplama Dönemi	7-15 Şubat 2023
Toplam Token	14,311
Ortalama Token/Tweet	28.6 ± 11.7
Token Uzunluk Aralığı	6-55
Kelime Dağarcığı Boyutu	5,190
Varlık Sayıları ve Dağılımı	
PER (Kişi)	429 (9.0%)
LOC (Konum)	2,494 (52.6%)
PHONE (Telefon)	287 (6.1%)
NEED (İhtiyaç)	636 (13.4%)
ORG (Kurum)	708 (14.9%)
LINK (URL)	188 (4.0%)
Varlık İstatistikleri	
Toplam Varlık	4,742 (100.0%)
Varlık Yoğunluğu (%)	33.1
Ortalama Varlık/Tweet	9.5 ± 6.5
Çoklu Varlık İçeren Tweet'ler (%)	90.2

3.2. Veri Etiketleme Şeması ve Referans Veri Dağılımı

Gold Standard veri kümesinin oluşturulması sırasında metinler, ‘Inside-Outside-Beginning’ (BIO) etiketleme formatına göre etiketlenmiştir. Bu formatta bir varlığın başlangıcı ‘B-’ (Beginning) etiketiyle, devam eden kısımları ‘I-’ (Inside) etiketiyle, varlık olmayan kelimeler ise ‘O’ (Outside) etiketiyle temsil edilmektedir. Veri kümesi, afet yönetimi için kritik öneme sahip altı temel varlık sınıfını içerecek şekilde yapılandırılmıştır. Model eğitimi aşamasında, hesaplama verimliliği için metinsel etiketler tamsayı değerlere dönüştürülmüştür. Çalışmada kullanılan varlık türleri, etiket haritası ve bunların veri kümesindeki dağılımı Tablo 3’de sunulmaktadır.

Table 3: Veri Kümesi Varlık Dağılımları ve Etiketleme Şeması

Varlık Türü	Etiket (BIO)	ID Eşlemesi	Açıklama
Varlık dışı	O	0	Arka plan kelimeleri, tematik hashtag’ler vb.
Kişi	B-PER, I-PER	1, 2	Kişi ad ve soyadları.
Konum	B-LOC, I-LOC	3, 4	Şehirler, mahalleler, sokaklar, binalar.
Telefon	B-PHONE, I-PHONE	5, 6	İletişim numaraları.
İhtiyaç	B-NEED, I-NEED	7, 8	Talep edilen yardım malzemeleri (çadır, gıda vb.).
Kurum	B-ORG, I-ORG	9, 10	Kurtarma ekipleri, STK’lar (AFAD, Ah-bap).
Bağlantı	B-LINK	11	Yardım talebi içeren URL’ler.

3.3. Teacher Model Geliştirme ve Ensemble Learning

Etiketleme sürecini otomatikleştirmek ve doğruluğu en üst düzeye çıkarmak amacıyla, bireysel modellere güvenmek yerine Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5 modellerinin kolektif kararına dayanan bir ‘Teacher’ mimarisi tasarlanmıştır. Bu kapsamda, 500 tweet’lik Gold Standard veri kümesindeki her token için üç farklı LLM tarafından üretilen tahminler ile gerçek etiketler birleştirilerek model eğitimi için 14.311 satırlık bir öznitelik matrisi (Stacking Dataset) oluşturulmuştur. Bu 14.311 satırlık öznitelik matrisini hazırlamak için, her LLM tarafından üretilen metin tabanlı BIO etiketleri, Tablo 3’da kesin olarak tanımlandığı şekilde karşılık gelen tamsayı ID’lerine (0-11) kodlanmıştır. Böylece her satır tek bir token’ı temsil etmiş; üç sayısal öznitelik sütunu (Gemini, Claude ve GPT’nin tamsayı tahminleri) ile bir hedef sütunu (insan tarafından etiketlenmiş Gold Standard tamsayı ID’si) içermiştir.

Bu ‘kolektif zeka’ yaklaşımını matematiksel olarak formalize etmek için, $\mathcal{T} = \{t_1, t_2, \dots, t_n\}$ verilen bir tweet’teki token dizisini, $\mathcal{M} = \{M_{\text{Gemini}}, M_{\text{Claude}}, M_{\text{GPT}}\}$ ise temel Large Language Model’ler kümesini (Level-0 sınıflandırıcılar) temsil etsin. Her token t_i için, bir model $m \in \mathcal{M}$ ’nin tahmini $y_{i,m} \in \mathcal{L}$ olarak tanımlanır; burada $\mathcal{L} = \{0, 1, \dots, 11\}$ ayrık NER etiket ID kümesidir.

Stacking mimarisinin ilk aşamasında, her token için bireysel LLM tah-

minlerinin birleştirilmesiyle bir ara öznitelik vektörü $\mathbf{v}_i$ oluşturulur:

$$\mathbf{v}_i = [M_{Gemini}(t_i), M_{Claude}(t_i), M_{GPT}(t_i)]^T \quad (1)$$

İkinci aşamada, θ ile parametrelendirilen ve $\mathcal{H}_\theta$ olarak gösterilen Gradient Boosting meta-sınıflandırıcı (Level-1 sınıflandırıcı), bu birleşik tahmin uzayını ground truth'a eşlemeyi öğrenir. Nihai ensemble tahmini $\hat{Y}_i$ şu şekilde hesaplanır:

$$\hat{Y}_i = \mathcal{H}_\theta(\mathbf{v}_i) \quad (2)$$

Meta-sınıflandırıcının optimal parametreleri θ^* , Gold Standard veri kümesi D_{gold} üzerinde sınıflandırma kaybı L minimize edilerek elde edilir:

$$\theta^* = \arg \min_{\theta} \sum_{(t_i, y_i^*) \in D_{gold}} L(\mathcal{H}_\theta(\mathbf{v}_i), y_i^*) \quad (3)$$

burada y_i^* , token t_i için insan tarafından etiketlenmiş gerçek etikettir. Bu formalizasyon, meta-sınıflandırıcının belirli varlık türleri ve bağlam sınırları için en güvenilir LLM'yi ağırlıklandırmayı matematiksel olarak öğrenmesini ve böylece bireysel model halüsinasyonlarını dinamik olarak en aza indirmesini sağlamaktadır.

Bu tasarım tercihi, tamsayı kodlu kategorik tahminler üzerinde ağaç tabanlı meta-öğrenmede yerleşik uygulamayla tutarlıdır; zira gradient-boosted ağaçlar girdi özniteliklerinin monoton dönüşümlerine karşı değişmezdir [19] ve ayrık değerleri ordinal yerine nominal kategoriler olarak etkili biçimde ele alan eşik tabanlı bölünme bulmaya dayanmaktadır [20].

En iyi birleştirme stratejisini belirlemek için bu veri kümesi üzerinde iki yöntem test edilmiştir. Tamsayı kodlu LLM tahminlerini girdi olarak işleyen Gradient Boosting tabanlı Stacking Modeli 0.9313 Macro F1 skoru elde ederken, modellerin bireysel performansına dayanan Weighted Voting yöntemi 0.9238 Macro F1 skoruna ulaşmıştır. Klasik baseline BERT mimarisinin performansı (0.8335) karşılaştırıldığında, önerilen Stacking yaklaşımı %11.73'lük anlamlı bir performans artışı sağlamıştır.

Gradient Boosting meta-sınıflandırıcı, GridSearchCV kullanılarak titizlikle optimize edilmiştir. Model dayanıklılığını garanti altına almak için token düzeyinde 5-Fold Cross-Validation prosedürü uygulanmıştır. Veri kümesi beş eşit alt kümeye bölünmüş; her iterasyonda meta-sınıflandırıcı dört fold üzerinde eğitilmiş ve görülmemiş kalan fold üzerinde değerlendirilmiştir. Hiperparametre ızgarası şu şekilde tanımlanmıştır: estimator sayısı $\in \{100, 200, 300\}$,

maksimum derinlik $\in \{3, 5, 7\}$ ve öğrenme oranı $\in \{0.01, 0.05, 0.1\}$. Optimal konfigürasyon şu şekilde belirlenmiştir: `n_estimators=300`, `max_depth=7` ve `learning_rate=0.01`.

Değerlendirmenin metodolojik titizliğini daha da güçlendirmek ve token'lar arasındaki olası tweet içi bağımlılıkların etkisini değerlendirmek amacıyla, Stacking modeli ayrıca tweet düzeyinde GroupKFold (5 fold) kullanılarak yeniden değerlendirilmiştir. Bu daha katı ayarda, aynı tweet'ten gelen tüm token'lar tek bir fold'a atanmakta ve dolayısıyla eğitim ile doğrulama kümelerinde asla aynı anda yer almamaktadır; bu da tweet içi bilgi sızıntısı olasılığını ortadan kaldırmaktadır. Bu değerlendirme stratejisiyle, Triple Gradient-Boost Stacking modeli $0.9219 (\pm 0.0117)$ Macro F1 skoru elde etmiş olup, bu, token düzeyi tahmine (0.9313) göre yalnızca $\sim 1\%$ 'lik bir azalmayı temsil etmektedir. Bu marjinal fark, LLM tahmin özniteliklerinde küçük ölçekli bir tweet içi öznitelik korelasyonu bulunsa da, Stacking ensemble'ın genelleme yeteneğinin sağlam kaldığını ve hem Baseline-BERT'i (0.8335, bkz. Tablo 6) hem de en güçlü bireysel LLM'yi (Gemini 2.5 Pro, 0.9245, bkz. Tablo 4) önemli ölçüde geride bırakmaya devam ettiğini doğrulamaktadır. Tam metodolojik şeffaflık sağlamak için her iki cross-validation stratejisi Tablo 6'de birlikte raporlanmıştır.

Bu bulgular ışığında, bireysel modellerin sınırlamalarını aşan Gradient Boosting Stacking mimarisi, bir sonraki aşamada üretilecek 'Silver Data' kümesinin kalitesini garanti altına almak üzere 'Teacher Model' olarak seçilmiştir. Ayrıca, Stacking meta-sınıflandırıcı eğitimi ile Student model doğrulaması arasındaki herhangi bir veri sızıntısını kategorik olarak dışlamak için, Stacking modeli yalnızca 500 tweet'lik Gold veri kümesi üzerinde eğitilmiş; nihai Student modeller ise eğitim hattının hiçbir aşamasına maruz kalmamış, tamamen izole 300 tweet'lik bir Blind Test Set üzerinde değerlendirilmiştir.

3.4. *Pseudo-Labeling ile Student Model Eğitimi*

Önceki aşamada 'Teacher' model olarak belirlenen Stacking mimarisi yüksek performans göstermesine rağmen, her tahmin için üç ayrı LLM API çağrısı gerektirmesi, büyük veri kümelerinde yüksek maliyet ve yavaş işlem sürelerine yol açmıştır. Bu hesaplama darboğazını aşmak ve modelin bilgisini daha hızlı, daha düşük maliyetli modellere aktarmak için uçtan uca bir pseudo-labeling stratejisi uygulanmıştır. Teacher'ın hard tahminleri, Student için doğrudan denetim hedefi olarak kullanılmıştır. Hinton et al. [5]'in klasik soft-target Knowledge Distillation'ı yerine bu hard-label varyantı benimsememizin nedeni, Teacher olarak kullanılan frontier LLM API'lerinin (GPT-

5, Claude Sonnet 4.5, Gemini 2.5 Pro) yapılandırılmış çıktı modunda token düzeyinde olasılık dağılımlarını sunmaması ve dolayısıyla sıcaklıkla yumuşatılmış soft hedefleri olanaksız kılmasıdır. Bu ayar, Symbolic Knowledge Distillation [6] gibi güncel LLM tabanlı hard-label aktarım paradigmatlarıyla tutarlıdır.

Süreç, veri havuzundan seçilen 3.000 adet ‘Etiketsiz Havuz Verisi’nin Teacher Model (Stacking Ensemble) tarafından işlenmesiyle başlamıştır. Bu işlemin sonucunda, LLM’lerin kolektif zekasıyla üretilen yüksek kaliteli sentetik etiketlerden oluşan ‘Silver Standard Dataset’ otomatik olarak oluşturulmuştur.

Elde edilen bu 3.000 adetlik Silver veri kümesi, düşük hesaplama maliyetli üç farklı Transformer mimarisinin (‘Student’lar) eğitiminde girdi olarak kullanılmıştır. Bu aşamada Türkçeye özgü dbmdz/bert-base-turkish-cased (Ana Student), çok dilli xlm-roberta-base ve daha hafif distilbert-base-turkish-cased modelleri sentetik veriyle eğitilmiştir.

Sürecin doğrulama aşamasında, eğitilen bu student modeller, iç kararlılığı ve genellemeyi ölçmek için kendi 3.000 örneklik Silver eğitim kümeleri üzerinde 5-Fold Cross-Validation ile değerlendirilmiştir. Tekrarlanabilirliği sağlamak amacıyla tüm student modeller; AdamW optimizör, 2×10^{-5} öğrenme oranı, 8 batch boyutu ve 512 token maksimum dizi uzunluğuyla 3 epoch boyunca fine-tune edilmiştir. Elde edilen sonuçlar, Silver veriyle eğitilen dbmdz/bert-base-turkish-cased modellerinin (Stacked-BERT-3k ve Voted-BERT-3k) 5-Fold Cross-Validation’da 0.9133’e varan Macro F1 skorlarına ulaşarak ‘Yüksek genelleme yeteneği’ sergilediğini göstermektedir. Bu skor, yalnızca sınırlı 500 cümlelik gold veriyle eğitilen baseline modelin performansından (Macro F1 = 0.8335) anlamlı ölçüde yüksektir.

3.5. Pseudo-Labeling ve Ölçekleme

Metodolojinin son aşamasında, Teacher tarafından üretilen pseudo-label’larla eğitilen ve başarısı kanıtlanan ‘Student’ modeller kullanılarak veri kümesi ölçeklendirilmiştir. 20.000 tweet’lik bir Silver veri kümesini doğrudan üçlü LLM ensemble ile üretmek yerine bu ara proxy-labeling adımının eklenmesinin gerekçesi, tamamen API maliyetleri ve inference gecikmesidir. 20.000 örnek için üç frontier LLM’yi eşzamanlı olarak sorgulamak, hesaplama açısından pahalıdır ve katı API rate limit’lerine tabidir. Stacked-BERT-3k modeli (3.000 Silver örnekle eğitilmiş dbmdz/bert-base-turkish-cased) zaten yüksek genelleme göstermiş olduğundan, çevrimdışı, sıfır maliyetli bir proxy

etiketleyici olarak stratejik biçimde kullanılmıştır. Sonuç olarak bu Stacked-BERT-3k modeli, veri havuzundaki kalan 17.000 etiketsiz tweet’i hızla etiketlemek için kullanılmıştır. Ortaya çıkan 17.000 satırlık ‘Pseudo-labeled’ veri kümesi, nihai modelin eğitimi için hazırlanmıştır. Veri kümesinin güvenilirliğini sağlamak için 5-Fold Cross-Validation uygulanmış ve eğitim sonuçları, `dbmdz/bert-base-turkish-cased` mimarisinin üretilen veriyi 0.9701 (± 0.0017) Macro F1 skoruyla tutarlı biçimde öğrendiğini doğrulamıştır (bkz. Tablo 9).

3.6. Model Seçimi ve Uygulama Detayları

Bu çalışmada önerilen ‘Teacher-Student’ mimarisini oluşturmak için iki farklı model grubu kullanılmıştır: etiketleme yeteneği sağlayan Large Language Model’ler (LLM) ve bu bilgiyi öğrenerek nihai sınıflandırmayı gerçekleştirecek Transformer tabanlı modeller.

3.6.1. Temel Modeller ve Prompt Konfigürasyonları

Türkçede sağlam semantik kavrayış sağlamak ve çalışmanın deneysel aşamasında (Ocak–Şubat 2026) kanıtlanmış çok dilli yeteneklere sahip, pazara öncülük eden state-of-the-art (SOTA) frontier modellerden yararlanmak amacıyla şu farklı mimariler seçilmiştir: Gemini 2.5 Pro [21], Claude Sonnet 4.5 [22] ve GPT-5 [23]. Tek bir modelin birden fazla örneğini stack’lemek yerine üç tamamen farklı mimari kullanma kararı, ensemble öğrenme teorisine derinlemesine dayanmaktadır. İki modelli alt kümeleri (ör. Gemini + Claude veya Gemini + GPT) karşılaştıran resmi bir ablasyon çalışması her modelin marjinal katkısını daha da nicelleştirebilecek olsa da, üç farklı mimari kullanmanın teorik temeli iyi kurulmuştur: ensemble performansı öncelikle temel sınıflandırıcılar arasındaki çeşitlilik ve düşük hata korelasyonu tarafından belirlenmekte ve heterojen model sayısını artırmak ensemble hatasını tutarlı biçimde azaltmaktadır [24]. Bu durum, üç ikili Cohen’s Kappa skorumun tamamının farklı olduğu ($\kappa = 0.9291, 0.8972, 0.8886$) etiketleyiciler arası uyum sonuçlarımızla (Tablo 5) ampirik olarak desteklenmekte ve her modelin Stacking ensemble’a benzersiz ve tamamlayıcı bir hata profili kattığını doğrulamaktadır. Metodolojimiz katı tekrarlanabilirlik için greedy decoding (temperature = 0.0) kullandığından, aynı modelin birden fazla örneği özdeş çıktılar üreterek sıfır varyansa yol açacaktı. Farklı SOTA mimarileri birleştirerek temel sınıflandırıcıların fonksiyonel çeşitliliğini en üst düzeye çıkardık ve meta-sınıflandırıcının düzeltmeyi etkili biçimde öğrenebileceği farklı hata profilleri elde ettik. Modellerin etiketleme başarısını en üst düzeye çıkarmak için özel bir ‘Prompt Engineering’ stratejisi uygulanmıştır. Her mod-

ele, ‘Afet Müdahale Uzmanı’ rolü atanmış (role-playing) yapılandırılmış bir sistem prompt’u verilmiştir. Bu prompt şablonu şunları içermektedir: (1) Görev Tanımı, (2) “Anlam Biçimden Üstündür” kısıtı, (3) BIO etiketleme şeması ve (4) modelin halüsinasyon yapmasını önleyen 14 açıklayıcı ‘Few-Shot’ senaryosu. Ayrıca çıktının doğrudan işlenebilmesi (parsing) için modellerin yalnızca sayısal ID’lerden oluşan katı bir JSON formatı üretmesi zorunlu kılınmıştır.

Tekrarlanabilirliği sağlamak ve LLM çıktılarındaki stokastik varyasyonu en aza indirmek için, üç model için de şu API parametreleri tutarlı biçimde kullanılmıştır: temperature=0.0 (greedy decoding), top_p=1.0 ve max_tokens=4096. Tüm API çağrıları, her sağlayıcının resmi API uç noktaları üzerinden gerçekleştirilmiştir. Kullanılan spesifik model sürümleri şunlardır: gemini-2.5-pro (Google AI Studio API), claude-sonnet-4-5-20250929 (Anthropic Messages API) ve gpt-5 (OpenAI Chat Completions API). Çalışmada kullanılan tam prompt şablonu Ek A’da sunulmaktadır.

3.6.2. Önceden Eğitilmiş Student Ağları

Bilgi aktarımı ve nihai sınıflandırma görevleri için Türkçe gibi sondan eklemeli dillerde iyi performans gösteren önceden eğitilmiş modeller tercih edilmiştir. Bu kapsamda şu mimariler test edilmiştir:

BERT (Bidirectional Encoder Representations from Transformers): Çalışmanın ana modeli olarak, MDZ Digital Library ekibi (dbmdz) tarafından Türkçe derlemler üzerinde eğitilen dbmdz/bert-base-turkish-cased modeli kullanılmıştır [25]. Bu model 12 katmana, 768 gizli birime ve 12 attention head’e sahiptir [26]. Büyük-küçük harfe duyarlı yapısı, panik anlarında tamamen büyük veya küçük harfle yazılmış metinlerde ve tweet’lerdeki yazım hatalarına rağmen sokak ve kişi adları gibi özel isimlerin tespiti için Named Entity Recognition (NER) görevlerinde kritik önemdedir. Uncased modellerin aksine “cased” yapı, Türkçenin morfolojik yapısında özel isimleri ayırt etmek için ekstra öznitelik sağlayarak yanlış pozitifleri azaltmaktadır.

Karşılaştırma Modelleri: BERT modelinin başarısını doğrulamak için metodoloji geliştirme sürecinde xlm-roberta-base (çok dilli model) [27] ve daha hafif bir mimari olan distilbert-base-turkish-cased [28] de eğitilmiş ve performansları karşılaştırılmıştır. Buradaki temel motivasyon, afet sırasında sunucu kaynaklarının kısıtlı olabileceği senaryolar (edge cihazlar) için performanstan ödün vermeden çalışabilecek en hafif mimarinin (DistilBERT gibi) belirlenmesidir. Deneyler dbmdz/bert-base-turkish-cased’in en yüksek performansı sunduğunu gösterdiğinden, bu mimari nihai model olarak

seçilmiştir.

4. Bulgular ve Tartışma

Bu bölümde, önerilen 'Data-Centric Artificial Intelligence' metodolojisinin etkinliği kapsamlı biçimde değerlendirilmektedir. Analiz, bireysel LLM'lerin few-shot performans değerlendirmesi ve baseline ile ensemble yaklaşımlar arasındaki metodolojik karşılaştırma ile başlamaktadır. Ardından, ölçeklenmiş veri kümelerinin iç tutarlılığı ve modelin gerçek dünya senaryolarındaki performansı değerlendirilmektedir. Bölüm; nihai mimari seçiminin detaylandırılması, modellerin izole bir kör test kümesi üzerinde değerlendirilmesi, bulguların state-of-the-art çalışmalarla karşılaştırılması ve veri merkezli yapay zeka paradigmasının daha geniş teorik çıkarımlarının tartışılmasıyla sona ermektedir.

4.1. Bireysel LLM'lerin Few-Shot Performans Değerlendirmesi

Projenin ilk aşamasında, geliştirilecek 'Stacking' mimarisine temel oluşturmak amacıyla üç farklı Large Language Model'in (Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5) ham etiketleme performansı ölçülmüştür. Bu deneyin temel amacı, herhangi bir gradyan tabanlı fine-tuning yapılmadan, 'Few-Shot' prompting stratejisi (Ek A'da detaylandırılmıştır) aracılığıyla in-context learning ile modellerin Türkçe deprem metinlerini anlama kapasitelerini ve hata profillerini ortaya koymaktır.

Yöntem ve Metrikler: Deneyler, uzmanlar tarafından doğrulanmış 500 tweet'lik 'Gold Standard' veri kümesi üzerinde gerçekleştirilmiştir. Modeller tarafından üretilen etiketler (Gemini_Tags, Claude_Tags, GPT_Tags), veri kümesindeki gerçek etiketlerle (Real_Tags) karşılaştırılmıştır. Sınıf dağılımındaki dengesizlik nedeniyle, değerlendirme için en güvenilir metrikler olarak Macro F1-Score ve Overall Accuracy kullanılmıştır.

Bireysel Model Sonuçları: Modellerin Gold Standard veri kümesindeki genel performansı Tablo 4'de özetlenmektedir. Üç model de %94'ün üzerinde doğruluk oranı elde etmiş, ancak Macro F1 skoruna göre Gemini 2.5 Pro modeli 0.9245 ile en yüksek performansı göstermiştir.

Table 4: Gold Standard Veri Kümesinde Bireysel LLM Performansları

Model	Macro F1-Score	Accuracy
Gemini 2.5 Pro	0.9245	0.9644
GPT-5	0.9037	0.9569
Claude Sonnet 4.5	0.8914	0.9418

Sınıf Bazlı Performans Analizi: Genel skorlar yüksek olsa da model performansı etiket türüne göre değişmektedir. Şekil 2’de sunulan sınıf bazlı Macro F1 karşılaştırması incelendiğinde, Gemini 2.5 Pro (mavi sütunlar) neredeyse tüm etiketlerde en tutarlı model olarak öne çıkarken, GPT-5 modeli (yeşil sütunlar) özellikle I-ORG (kurum devamı) etiketinin tespitinde belirgin bir düşüş yaşamıştır.




Figure 2: LLM Modellerinin Sınıf Bazlı Macro F1 Skor Karşılaştırması

Hata Analizi ve Confusion Matrix’ler: Modellerin yaptığı hataların doğasını anlamak için Confusion Matrix’ler incelenmiştir. Tüm modellerin deprem verisi için kritik olan ‘Konum’ (LOC) etiketlerinde zorlandığı, ancak hata türlerinin farklılaştığı belirlenmiştir.

Şekil 3’de görüldüğü üzere, modeller B-LOC (3) ve I-LOC (4) etiketlerini ayırt etmekte zorlanmaktadır. Özellikle GPT-5 modeli, 152 I-LOC etiketini yanlışlıkla B-LOC olarak tahmin etmiş (bir adresin devamını yeni bir adresin

başlangıcı sanmış), bu da varlık sınırlarını ve yapısal bütünlüğü korumada Gemini 2.5 Pro kadar başarılı olmadığını göstermektedir.




Figure 3: NER Görevi için LLM Modellerinin Confusion Matrix'leri

Bireysel LLM'ler güçlü bir temel sağlasa da, sergiledikleri tutarsızlıklar ve farklılaşan hata profilleri (ör. GPT-5'in konum sınırlarındaki hatası, Claude Sonnet 4.5'in düşük duyarlılığı), tek bir modele güvenmenin uygulanabilir olmadığını göstermektedir.

Etiketleyiciler Arası Uyum ve Tekrarlanabilirlik: Silver Standard veri üretim sürecinin tekrarlanabilirliğini sağlamak ve üç LLM etiketleyici arasındaki konsensüs derecesini nicelleştirmek amacıyla, 500 cümlelik Gold Standard veri kümesi (14.311 token) üzerinde etiketleyiciler arası uyum analizi yapılmıştır. Bölüm 3.6.1'de detaylandırıldığı üzere, tüm LLM API çağrıları 2026 yılında resmi API uç noktaları kullanılarak, temperature 0.0 (greedy decoding) ve max_tokens 4096 olmak üzere sıkı biçimde kontrol edilen parametrelerle gerçekleştirilmiştir.

Modeller arasındaki etiketleme tutarlılığını ölçmek için Pearson (r) ve Spearman (ρ) korelasyon katsayıları ile Cohen's Kappa (κ) skorları ikili olarak hesaplanmıştır. Korelasyon metrikleri genel eğilim uyumunu gösterirken, NER etiketleri (ör. B-LOC, I-PER) matematiksel büyüklükler değil nominal kategoriler olduğundan, Cohen's Kappa birincil ve en sağlam metrik olarak raporlanmıştır. Karşılaştırmalı sonuçlar Tablo 5'de sunulmaktadır.

Table 5: 500 Cümlelik Gold Standard (14.311 Token) Üzerinde LLM’ler Arası Etiketleyici Uyumu ve Korelasyon Metrikleri

Etiketleyici Çifti	Pearson (r)	Spearman (ρ)	Cohen’s κ
Gemini 2.5 Pro & GPT-5	0.9476	0.9455	0.9291
Gemini 2.5 Pro & Claude Sonnet 4.5	0.9168	0.9114	0.8972
GPT-5 & Claude Sonnet 4.5	0.9181	0.9143	0.8886

Tablo 5’deki sonuçlar, tüm LLM çiftlerinde “Neredeyse Mükemmel Uyum” ($\kappa \geq 0.81$) olduğunu göstermektedir. En yüksek ikili uyum, Gemini 2.5 Pro ile GPT-5 arasında gözlemlenmiştir ($\kappa = 0.9291$). Bu yüksek uyum skorları, çoklu-LLM etiketleme sürecinin güvenilirliğini resmî olarak doğrulamakta ve Stacking mekanizması tarafından üretilen Silver Standard verinin sağlam, tekrarlanabilir bir konsensüs üzerine inşa edildiğini kanıtlamaktadır. Yüksek genel uyuma rağmen, belirli varlık sınırı durumlarında yoğunlaşan ikili anlaşmazlıklar (ör. Şekil 3’deki confusion matrix’lerde gösterilen I-LOC ile B-LOC ayrımları), Stacking ensemble’ın bireysel modelleri geride bırakmak için yararlandığı tamamlayıcı hata örüntülerini sağlamaktadır. Ayrıca, temel sınıflandırıcıların fonksiyonel çeşitliliğinin en üst düzeye çıkarılması, meta-sınıflandırıcının dayanıklılığını ve doğruluğunu önemli ölçüde artırmaktadır [24]. Dolayısıyla bu bulgular, modellerin benzersiz güçlü yönlerini birleştirirken bireysel hatalarını sistematik olarak azaltan bir ‘Stacking Ensemble’ yaklaşımının gerekliliğini deneysel olarak göstermektedir.

4.2. Yöntem Karşılaştırması (Baseline ve Ensemble)

Çalışmanın bu aşamasında, sınırlı veri kaynağına sahip (500 tweet) bir afet senaryosunda geleneksel ‘fine-tuning’ yaklaşımının performansı, önerilen ‘Data-Centric Ensemble Learning’ yaklaşımıyla karşılaştırılmıştır.

Temel hipotezimiz, milyarlarca parametreyle eğitilmiş Large Language Model’lerin (LLM) ‘kalabalıkların bilgeliğini’ (wisdom of crowds) kullanan bir yapının, az miktarda veriyle eğitilmiş standart bir BERT modelinden daha başarılı olacağıdır.

Yöntem: Objektif bir karşılaştırma sağlamak için, eğitim gerektiren modeller (Model A ve Model B) aynı 500 satırlık ‘Gold Standard’ veri kümesi üzerinde 5-Fold Cross-Validation yöntemiyle test edilmiştir.

- **Model A (Baseline):** Standart dbmdz/bert-base-turkish-cased modeli 500 cümlelik veriyle eğitilmiş ve Macro F1 skoru elde edilmiştir.

- **Model B (Stacking Ensemble):** Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5’in tahmin çıktılarını öznitelik olarak kullanan Gradient Boosting tabanlı bir meta-sınıflandırıcı; Model A ile sonuçların tutarlılığını sağlamak için aynı 5-fold cross-validation yöntemiyle değerlendirilmiştir.
- **Referans Modeller:** Bireysel LLM sonuçları ve Macro F1 ağırlıklı voting sonuçları referans olarak tabloya (Tablo 6) eklenmiştir.

Table 6: Token Düzeyi ve Tweet Düzeyi Cross-Validation Stratejileri Altında Model A ve Ensemble Yöntemlerinin Performans Karşılaştırması

Model Yöntemi	Açıklama	Değerlendirme Yöntemi	Macro F1
Model A	BERT Baseline	5-Fold Cross-Validation	0.8335
Bireysel LLM	Claude Sonnet 4.5	Few-Shot (500 Gold)	0.8914
Bireysel LLM	GPT-5	Few-Shot (500 Gold)	0.9037
Bireysel LLM	Gemini 2.5 Pro	Few-Shot (500 Gold)	0.9245
Simple Weighted Voting	F1 Skoruna Göre Ağırlıklandırma	Inference (500 Gold)	0.9238
Model B	Gradient-Boost Stacking	Token düzeyi 5-Fold CV	0.9313
Model B	Gradient-Boost Stacking	Tweet düzeyi GroupKFold (5-Fold)	0.9210

Tablo 6’deki veriler incelendiğinde, önerilen Stacking yaklaşımı (0.9313), geleneksel Baseline modeli (0.8335) %11.73’lük bir farkla geride bırakmıştır. Ayrıca Stacking yöntemi, ‘Simple Voting’ (0.9238) yöntemini de geride bırakarak öğrenilebilir bir birleştirme mekanizmasının (Gradient Boosting) önemini vurgulamıştır. Bu nedenle Stacking modeli, proje için ‘Teacher’ model olarak seçilmiştir.

4.2.1. Ablasyon Çalışması: İkili ve Üçlü Stacking Varyantları

Üç LLM’nin tamamının gerekli olup olmadığı endişesini ele almak için, 500 tweet’lik Gold Standard üzerinde halihazırda üretilmiş LLM tahminlerini kullanan ve ek API çağırısı gerektirmeyen çevrimdışı bir ablasyon çalışması yürütülmüştür. Tablo 4’de raporlanan, aynı Gold Standard üzerindeki tek model baseline’ları 0.8914 (Claude Sonnet 4.5), 0.9037 (GPT-5) ve 0.9245 (Gemini 2.5 Pro) Macro F1 skorlarına ulaşmaktadır. Bunların üzerine, üç ikili kombinasyonun tamamı (Claude+GPT, Gemini+GPT, Claude+Gemini) ve Üçlü ensemble, Bölüm 3.3’te Üçlü Stacking modeline uygulanan aynı 5-fold

tweet düzeyi GroupKFold protokolü altında hem RandomForest hem de GradientBoosting meta-sınıflandırıcılarla değerlendirilmiştir. Sonuçlar Tablo 7’de sunulmaktadır.

Table 7: Ablasyon Çalışması: 500 Tweet’lik Gold Standard Üzerinde İkili ve Üçlü Stacking Varyantları (5-Fold Tweet Düzeyi GroupKFold, RandomForest ve GradientBoosting Üzerinde GridSearchCV)

Varyant	Meta-Sınıflandırıcı	Macro F1
İkili: Claude + GPT	RandomForest	0.9006
İkili: Claude + GPT	GradientBoosting	0.9194
İkili: Gemini + GPT	RandomForest	0.9199
İkili: Gemini + GPT	GradientBoosting	0.9272
İkili: Claude + Gemini	RandomForest	0.9242
İkili: Claude + Gemini	GradientBoosting	0.9256
Üçlü: Üç Model	RandomForest	0.9188
Üçlü: Üç Model	GradientBoosting	0.9219

Üç LLM’li Stacking mimarisinin tercihini üç gözlem desteklemektedir. Birincisi, en iyi ikili varyant (GradientBoosting ile Claude+Gemini, Macro F1 = 0.9256), Üçlü ensemble’ı (0.9219) yalnızca 0.0037 Macro F1 puanıyla marjinal olarak geçmektedir. Fold bazlı skorlar üzerinde yapılan eşleştirilmiş t -testi $t = -0.263$, $p = 0.8054$ sonucunu vermekte; bu da farkın $\alpha = 0.05$ düzeyinde istatistiksel olarak anlamlı olmadığını ve iki mimarinin kalibrasyon kümesinde istatistiksel olarak eşdeğer olduğunu göstermektedir. İkincisi, Üçlü ensemble, meta-sınıflandırıcı varyantları arasında daha kararlı bir performans profili sergilemektedir: en zayıf ikili varyant (RandomForest altında Claude+GPT) 0.9006’ya düşerken, Üçlü aynı meta-sınıflandırıcı altında 0.9188’de kalmakta ve üç modelin tamamının dahil edilmesinin herhangi bir tek etiketleyicinin başarısızlığına karşı yedeklilik sağladığını göstermektedir. Üçüncüsü, herhangi bir LLM sağlayıcısının ihtiyaç anında kesinti yaşayabileceği veya rate limit’e takılabileceği operasyonel afet senaryolarında, üçlü ensemble bir sağlayıcı geçici olarak kullanılamaz hale gelse bile pseudo-labeling kapasitesini korumaktadır; bu, ikili bir sistemin sunamayacağı bir özelliktir. Bu bulgular, iki modellen bir varyantın Gold kalibrasyon kümesinde prensipte karşılaştırılabilir doğruluğa ulaşabileceğini, ancak üçüncü modelin marjinal maliyetinin, en iyi ikiliyle istatistiksel eşdeğerliği ve gerçek dünya dağıtım kısıtları altındaki operasyonel dayanıklılığıyla dengelendiğini göster-

mektedir.

4.2.2. Silver Standard Veri ile Yöntem Doğrulaması

Deney kapsamında, Teacher (Stacking) ve Referans (Voting) modelleri tarafından etiketlenen 3.000’er adet ‘Silver Data’ kümesi kullanılmıştır. Sentetik verinin kalitesini ve modelden bağımsız performansını ölçmek için bu veriyle yalnızca bert-base değil, xlm-roberta ve distilbert mimarileri de eğitilmiştir.

Student modellerin Teacher kalibrasyonunda kullanılan veriden bağımsız olarak değerlendirilmesini sağlamak ve 500 Gold Standard kümesinden herhangi bir dolaylı bilgi sızıntısını önlemek amacıyla, bu aşamada eğitilen tüm Student modeller kendi 3.000 örneklik Silver eğitim kümeleri üzerinde 5-Fold Cross-Validation ile değerlendirilmiştir. Bu değerlendirme, Gold Standard verisi yeniden kullanılmadan model kararlılığı, veri kalitesi ve genelleme yeteneğine ilişkin sağlam bir iç ölçüm sunmaktadır. İzole 300 cümlelik Blind Test Set, yalnızca ölçeklenmiş 17k modellerin nihai değerlendirmesi (Bölüm 4.6) için ayrılmış olup bu ara aşamada model veya mimari seçiminde asla kullanılmamıştır. Cross-validation değerlendirmesinin sonuçları Tablo 8’de sunulmaktadır.

Table 8: Student Modellerin Genelleme Performansı: 3.000 Silver Veri Üzerinde 5-Fold Cross-Validation

Eğitim Verisi	Model	Macro F1	$\pm$ Std	Prec.
500 Gold (Baseline)	bert-base-turkish-cased	0.8335	–	–
3000 Stacked Silver	bert-base-turkish-cased	0.9065	0.0093	0.9027
3000 Stacked Silver	xlm-roberta-base	0.8961	0.0120	0.8929
3000 Stacked Silver	distilbert-base-turkish-cased	0.8279	0.0098	0.8284
3000 Voted Silver	bert-base-turkish-cased	0.9133	0.0057	0.9049
3000 Voted Silver	xlm-roberta-base	0.8960	0.0068	0.8900
3000 Voted Silver	distilbert-base-turkish-cased	0.8281	0.0078	0.8247

Tablo 8’deki veriler incelendiğinde, önerilen ‘Data-Centric Artificial Intelligence’ yaklaşımının başarısı üç temel alanda doğrulanmaktadır.

İlk olarak, LLM tarafından üretilen sentetik verilerle eğitilen tüm Student modeller, yalnızca 500 manuel etiketli veriyle eğitilen Baseline modeli (Macro F1=0.8335) tutarlı ve anlamlı biçimde geride bırakmaktadır. Her iki ensemble stratejisi de 5-Fold Cross-Validation’da 0.9133’e varan Macro F1

skorlarına ulaşan, yüksek genelleme yeteneğine sahip student modeller üretmiştir. Hem Voted-BERT-3k (Macro F1=0.9133) hem de Stacked-BERT-3k (Macro F1=0.9065) modelleri, Baseline'ı önemli ölçüde aşarak yaklaşık 8 puanlık bir iyileşme sağlamıştır. Bu sonuç, yüksek kaliteli sentetik verinin ('Smart Data') az miktarda manuel veriden daha öğretici olduğunu kanıtlamaktadır.

İkinci olarak, iki ensemble yöntemi (Stacking ve Voting) arasındaki performans farkı tüm mimarilerde ihmal edilebilir düzeydedir. 5-Fold Cross-Validation'da Stacked Silver (Macro F1=0.9065) ve Voted Silver (Macro F1=0.9133) ile eğitilen bert-base-turkish-cased modelleri yalnızca 0.0068 Macro F1 puanı farklılaşmakta olup bu, rastgele varyasyon aralığının içinde kalan bir marjdir; xlm-roberta-base ve distilbert-base-turkish-cased mimarilerinde de benzer şekilde dar farklar gözlemlenmiştir (genel olarak 0.01'in altında). Bu bulgu, her iki ensemble stratejisinin de karşılaştırılabilir kalitede Silver veri ürettiğini ve temel katkının spesifik birleştirme yönteminden ziyade LLM tabanlı sentetik veri üretim mekanizmasının kendisinde yattığını göstermektedir.

Son olarak, parametre sayısı önemli ölçüde daha az olan DistilBERT modelinin bile sentetik veriyle eğitildiğinde 5-Fold Cross-Validation'da 0.83 civarında Macro F1 skorları elde etmesi dikkat çekicidir; bu, LLM tarafından üretilen Silver veri kümesinin hafif mimarilerle bile öğrenmeyi mümkün kılacak kadar bilgilendirici olduğunu göstermektedir. DistilBERT'in Macro F1=0.9338'e ulaştığı Bölüm 4.3'deki ölçekli deneylerle daha da pekişen bu gözlem, yüksek kaliteli sentetik verinin rekabetçi performansı mümkün kıldığını ve kaynak kısıtlı ortamlarda dağıtımı desteklediğini doğrulamaktadır.

4.2.3. Ölçekleme ve Nihai Veri Kümesi

Student modellerin başarısının doğrulanmasının ardından sürecin son adımı olan 'Ölçekleme' gerçekleştirilmiştir. Stacked-BERT-3k modeli (yani 3.000 Stacked Silver örnekle eğitilen dbmdz/bert-base-turkish-cased), cross-validation ve kör testlerdeki yüksek kararlılığı ile Teacher modelinin (Stacking, Macro F1=0.9313) üstün baseline performansı nedeniyle başlangıçta önceliklendirilmiş olsa da, büyük ölçekli dayanıklılıklarını kapsamlı biçimde karşılaştırmak amacıyla nihai olarak hem Stacked-BERT-3k hem de Voted-BERT-3k modelleri ölçekleme sürecinde kullanılmıştır. Bu modeller kullanılarak, veri havuzunda kalan 17.000 ham veri otomatik olarak etiketlenmiştir. Bu işlemin sonucunda, manuel insan emeği harcanmadan iki ayrı, devasa pseudo-labeled eğitim kümesi (17k Stacked ve 17k Voted) elde edilmiştir. Bu 17.000 örnek-

lik ölçeklenmiş kümeler önce iç tutarlılık analizlerine tabi tutulmuş, ardından Bölüm 4.6’de sunulan kör test kümesinde değerlendirilecek nihai modellerin (Stacked-BERT-17k ve Voted-BERT-17k) eğitimine temel oluşturmuştur.

4.3. Ölçeklenmiş Veri Kümelerinin İç Tutarlılığı ve Kalite Doğrulaması

Pseudo-labeling sürecinin başarısı, üretilen büyük ölçekli (17k) sentetik verinin kalitesine ve tutarlılığına doğrudan bağlıdır. Ancak yalnızca iç train-test bölünmelerine güvenmek, etiketlerin gerçek doğruluğunu doğrulamak yerine yalnızca bir modelin öğretmeninin örüntülerini ezberleme yeteneğini göstermek riskini taşımaktadır. Bu metodolojik zorluğu ele almak için iki yönlü bir doğrulama stratejisi benimsenmiştir: (1) pseudo-labeled verinin *öğrenilebilirliğini* ve iç tutarlılığını ölçmek için 5-Fold Cross-Validation ve (2) etiket kalitesini uzman yargısına karşı bağımsız olarak doğrulamak için bir Human Annotation Agreement denetimi.

4.3.1. Cross-Validation Analizi

Pseudo-labeled veri kümelerinin iç tutarlılığını ve gürültü düzeylerini ölçmek için, hem Stacked hem de Voted 17.000 tweet’lik veri kümeleri, üç Transformer mimarisi üzerinde 5-Fold Cross-Validation ile değerlendirilmiştir. Tek bir 80/20 bölünmesinin aksine bu yaklaşım, sonuçların şanslı bir bölümlenmeden kaynaklanma riskini azaltarak standart sapmayla birlikte veri kalitesinin sağlam bir tahminini sunmaktadır. Sonuçlar Tablo 9’de sunulmaktadır.

Table 9: Pseudo-Labeled 17.000’lik Veri Kümelerinin İç Tutarlılığı (5-Fold Cross-Validation)

Veri Kümesi Kaynağı	Model	Macro F1	$\pm$ Std	Prec.	Recall
17k ‘Stacked’	bert-base-turkish-cased	0.9701	0.0017	0.9689	0.9714
17k ‘Stacked’	xlm-roberta-base	0.9482	0.0013	0.9470	0.9495
17k ‘Stacked’	distilbert-base-turkish-cased	0.9338	0.0011	0.9326	0.9351
17k ‘Voted’	bert-base-turkish-cased	0.9666	0.0016	0.9642	0.9691
17k ‘Voted’	xlm-roberta-base	0.9431	0.0017	0.9404	0.9459
17k ‘Voted’	distilbert-base-turkish-cased	0.9280	0.0014	0.9259	0.9301

Tablo 9’de sunulan performans metriklerinin, modellerin insan tarafından etiketlenmiş gold standard veriler üzerindeki nihai performansını değil, Teacher model tarafından üretilen büyük ölçekli pseudo-labeled veri kümesinden öğrenme başarısını temsil ettiğini vurgulamak önemlidir. Tablo 9’deki

veriler incelendiğinde, Stacking tabanlı veri üretim yaklaşımının başarısı iki temel boyutta doğrulanmaktadır. İlk olarak, test edilen model mimarisinden bağımsız olarak (BERT, RoBERTa, DistilBERT), ‘Stacked’ veri kümesiyle eğitilen tüm modeller, ‘Voted’ veri kümesiyle eğitilen karşılıklarına kıyasla tutarlı bir performans artışı sergilemiştir. Örneğin BERT modeli için Macro F1 skoru 0.9666’dan 0.9701’e yükselirken, DistilBERT modelinde de benzer bir iyileşme kaydedilmiştir (0.9280 $\rightarrow$ 0.9338). Bu bulgu, Stacking mekanizmasının Voting yöntemine kıyasla daha az gürültülü ve daha öğretici bir veri kümesi ürettiğini doğrulamaktadır. İkinci olarak, tüm konfigürasyonlardaki istisnai düzeyde düşük standart sapmalar (≤ 0.0017), her iki veri kümesinin de minimum gürültü veya iç çelişkiyle son derece kararlı ve öğrenilebilir olduğunu göstermektedir. Mimari açıdan bakıldığında, bert-base-turkish-cased modeli en yüksek iç tutarlılık skorunu (%97.01) elde ederken, hafif DistilBERT modeli de %93.38’lik yüksek bir başarı oranı yakalayarak önerilen yöntemin sunduğu veri kalitesini ve platformlar arası kullanılabilirliği doğrulamıştır.

4.3.2. Human Annotation Agreement (*Pseudo-Label Kalite Denetimi*)

Cross-validation iç tutarlılığı gösterse de, pseudo-label’ların kendilerinin doğru olduğunu değil, yalnızca modellerin bunları tutarlı biçimde öğrenebildiğini doğrulayabilmektedir. Bu sınırlamayı ele almak için, Teacher tarafından üretilen etiketlerin kalitesini bağımsız olarak doğrulamak üzere iki aşamalı bir human annotation agreement çalışması yürütülmüştür: önce iki bağımsız insan etiketleyici arasındaki güvenilirlik ölçülmüş, ardından uzlaştırılmış insan referansı Teacher modelin tahminleriyle karşılaştırılmıştır.

17.000 tweet’lik Stacked pseudo-labeled veri kümesinden rastgele 100 tweet’lik bir örneklem çekilmiştir. Bu tweet’ler, 500 tweet’lik Gold Standard kümesi için kullanılan aynı BIO etiketleme yönergeleri izlenerek iki etiketleyici tarafından bağımsız olarak yeniden etiketlenmiştir. Her iki etiketleyici de Türkçe NER etiketlemede önceden deneyime sahipti ve Gold Standard’ın etiketlenmesine daha önce katılmıştı. Hiçbir etiketleyici, etiketleme sürecinde Teacher modelin tahminlerine erişememiştir. İki etiketleyici arasındaki anlaşmazlıklar daha sonra gözden geçirilerek tartışma yoluyla çözülmüş ve Teacher model karşılaştırmasında kullanılan tek bir uzlaştırılmış referans kümesi üretilmiştir.

İnsan referansının kendi güvenilirliğini değerlendirmek için, iki etiketleyici arasındaki uyum, hem tam 12 sınıf düzeyinde hem de ikili varlık/varlık dışı düzeyinde Pearson korelasyonu, Spearman korelasyonu, Cohen’s Kappa ve token düzeyi doğruluk kullanılarak hesaplanmıştır. Sonuçlar Tablo 10’da

raporlanmaktadır.

Table 10: 100 Tweet’lik Denetim Örnekleminde (2.583 Token) İki Bağımsız Etiketleyici Arasındaki Uyum

Metrik	Skor
Pearson Korelasyonu (r)	0.9363
Spearman Korelasyonu (ρ)	0.9492
Cohen’s Kappa (Tüm Etiketler)	0.9485
Token Düzeyi Doğruluk (Tüm Etiketler)	0.9702
Cohen’s Kappa (Varlık - Varlık Dışı)	0.9563
Varlık İkili Doğruluğu	0.9795
Değerlendirilen Toplam Token	2,583
Anlaşmazlık Oranı	2.98% (77/2,583)

İki etiketleyici arasındaki 0.9485’lik Cohen’s Kappa skoru, “Neredeyse Mükemmel Uyum” aralığında ($\kappa \geq 0.81$) yer almakta ve orijinal 500 tweet’lik Gold Standard kümesi için belirlenen etiketleyiciler arası eşiği ($\kappa > 0.85$) aşarak bu denetimde kullanılan insan referans etiketlerinin güvenilir olduğunu doğrulamaktadır. %2.98’lik genel anlaşmazlık oranı, etiketleme yönergelerinin bağımsız etiketleyiciler arasında son derece tutarlı etiketler üretecek kadar iyi tanımlanmış olduğunu göstermektedir.

Bu uzlaştırılmış referans üzerine inşa edilerek, Teacher (Stacking modeli) etiketleri ile uzlaştırılmış İnsan etiketleri arasındaki uyum, Cohen’s Kappa katsayısı ve token düzeyi doğruluk kullanılarak ölçülmüştür. Sonuçlar Tablo 11’de özetlenmektedir.

Table 11: Human Annotation Agreement: Teacher Etiketleri ile Uzman Etiketleri (100 Tweet, 2.665 Token)

Metrik	Skor
Cohen’s Kappa (Tüm Etiketler)	0.9709
Token Düzeyi Doğruluk	0.9850
Cohen’s Kappa (Varlık - Varlık Dışı)	0.9732
Varlık İkili Doğruluğu	0.9884
Değerlendirilen Toplam Token	2,665
Anlaşmazlık Oranı	1.5% (40/2,665)

0.9709’luk Cohen’s Kappa skoru, Landis ve Koch (1977) ölçeğine göre

“Neredeyse Mükemmel Uyum” aralığında ($\kappa \geq 0.81$) yer almakta ve Stacking Teacher model tarafından üretilen pseudo-label’ların uzman düzeyine yakın kalitede olduğunu doğrulamaktadır. %98.50’lik token düzeyi doğruluk ve yalnızca %1.5’lik anlaşmazlık oranı bu sonucu daha da pekiştirmektedir.

Kalan anlaşmazlıkların doğasına daha derin bir bakış sağlamak amacıyla, Teacher etiketlerinin varlık düzeyi performansı (insan etiketleri ground truth kabul edilerek değerlendirilmiştir) Tablo 12’de sunulmaktadır.

Table 12: Teacher ve İnsan Etiketleri Arasındaki Varlık Düzeyi Uyum

Varlık	Precision	Recall	F1-Score	Support
B-LINK	1.00	1.00	1.00	42
B-LOC	0.99	0.99	0.99	139
I-LOC	0.99	0.99	0.99	302
B-PHONE	1.00	1.00	1.00	12
I-PHONE	1.00	1.00	1.00	21
B-NEED	0.96	0.96	0.96	94
I-NEED	0.87	0.93	0.90	28
B-ORG	0.95	0.92	0.94	132
I-ORG	0.85	0.73	0.79	15
B-PER	0.89	0.94	0.91	33
I-PER	0.97	1.00	0.98	31
Macro Avg	0.95	0.95	0.95	849
Weighted Avg	0.97	0.97	0.97	849

Varlık düzeyi analiz, Teacher modelin LINK (F1=1.00), PHONE (F1=1.00) ve LOC (F1=0.99) gibi iyi tanımlanmış varlık türlerinde insan uzmanlarla neredeyse mükemmel bir uyum sağladığını ortaya koymaktadır. Anlaşmazlığın temel kaynağı, çok düşük destek sayısına (15 token) sahip I-ORG sınıfında (F1=0.79) yoğunlaşmaktadır. Bu sınıfta Precision’a (0.85) kıyasla belirgin ölçüde daha düşük Recall (0.73), Teacher modelin diğer token’ları I-ORG olarak yanlış etiketlemekten ziyade kurum devam token’larını kaçırma eğiliminde olduğuna işaret etmektedir. Bu sonuçlar, pseudo-labeled veri kümesinin güvenilir Student modellerin eğitimi için yeterli kalitede olduğunu ve kalan anlaşmazlıkların sistematik etiketleme hatalarından değil gerçek dilsel belirsizlikten kaynaklandığını doğrulamaktadır.

4.4. Gerçek Dünya Senaryosu ve Nitel Değerlendirme (Vaka Çalışması)

Eğitilen nihai modelin (Stacked-BERT-17k) gerçek dünya verileri üzerindeki davranışını gözlemlemek ve sınırlamalarını eleştirel biçimde değerlendirmek amacıyla, karmaşık varlık yapıları ve semantik belirsizlikler içeren zorlu afet tweet’leri üzerinde canlı inference testleri yapılmıştır.

Örnek Tweet-1: “@OzgunErgin @AFADBaskanlik @ahbap @PincTivi @BabalaTv @haluklevent @lordsinov @ProfDemirtas Acil yardım !!! Hatay / Odabaşı mah.Akademi Hastanesi’nin yanındaki bina Elçiler apt. !!! #acildeprem #hatayyardimbekliyor @AFADBaskanlik @AFADHatay @haluklevent @OguzhanUgur”

Nihai modelin bu metin üzerindeki tahminleri ve doğruluk analizi Tablo 13’de sunulmaktadır.

Table 13: Canlı Inference Analizi 1: Kurumsal Mention’lar ve Semantik Belirsizlik

Token	Etiket	Doğruluk	Analiz
@AFADBaskanlik	B-ORG	✓ Doğru	Resmî kurum hesabı doğru şekilde tanınmıştır.
@haluklevent	O	✓ Doğru	Ünlü mention’ı varlık dışı olarak doğru şekilde göz ardı edilmiştir.
Hatay / Odabaşı	B-LOC, I-LOC	✓ Doğru	Konum tespiti başarılıdır.
mah.Akademi Hastanesi’nin	I-LOC, I-LOC	× Yanlış	Semantik Belirsizlik: Mekânsal referans olarak kullanıldığı için kurum (ORG) yerine fiziksel konum (LOC) olarak sınıflandırılmıştır.

Analiz, modelin resmî kurumsal hesaplar (ORG) ile ünlü mention’larını (O) başarıyla ayırt ettiğini ve yönergelere sıkı sıkıya bağlı kaldığını ortaya koymuştur. Ancak model semantik belirsizlikte zorlanmakta, ‘Akademi Hastanesi’ni kurum yerine konum olarak yanlış sınıflandırmaktadır. Bu bulgu, Bölüm 4.6.2’de tartışılan I-ORG ve I-LOC örtüşmelerine ilişkin confusion matrix hatalarıyla doğrudan örtüşmektedir.

Modelin yapılandırılmamış metin içinde derin bağlamsal mantığı ve hayatta kalma durumu filtrelemesini işleme yeteneğini test etmek için ikinci bir canlı tahmin gerçekleştirilmiştir.

Örnek Tweet-2: “Tıp fakültesi dönem üç’ten öğrenci arkadaşımız Hatice Sena 80 saat sonra Adıyaman’da kardeşleriyle birlikte vefat haberi geldi. Bir diğer arkadaşımız evleri yıkıldı, akrabaları enkaz altında. Adıyaman diye bir yer de kalmadı. Acil yardım talep ediyorlar <https://t.co/dqq00qvQ0p>”

Nihai modelin bu bağlam yoğun veri üzerindeki tahminleri Tablo 14’de detaylandırılmaktadır.

Table 14: Canlı Inference Analizi 2: Derin Bağlam ve Kural Sınırlamaları

Token	Etiket	Doğruluk	Analiz
Adıyaman’da	B-LOC	✓ Doğru	Konum doğru şekilde çıkarılmıştır.
https://t.co/...	B-LINK	✓ Doğru	URL bağlantısı doğru şekilde tanımlanmıştır.
Hatice Sena	B-PER, I-PER	× Yanlış	Derin Bağlam Hatası: Model, hayatta kalma durumu kuralını uygulayamamış ve vefat etmiş bir kişiyi kurtarılması gereken bir mağdur olarak etiketlemiştir. Beklenen etiket ‘O’ idi.

Bu vaka, Stacked-BERT-17k modelinin konumlar ve bağlantılar gibi standart adlandırılmış varlıkları doğru biçimde çıkarırken, karmaşık mantıksal filtreleme için gereken çok adımlı (multi-hop) akıl yürütmeden yoksun olduğunu göstermektedir. Model, vefat etmiş bir bireyi aktif bir mağdur olarak etiketleyerek derin bağlamsal kuralları işlemedeki sınırlılığını ortaya koymakta, ancak semantik ilişkilendirmesi (bir ismi tanıma) sağlam kalmaktadır.

Nitel analizlerdeki bu başarıyı nicel olarak doğrulamak ve en uygun model mimarisini belirlemek için bir sonraki aşamada kapsamlı mimari testler yapılmıştır.

4.5. Nihai Model ve Mimari Karşılaştırması (Model Seçimi ve Dayanıklılık)

Çalışmanın bu aşamasına kadar yürütülen iç tutarlılık analizleri (Bölüm 4.3) ve gerçek dünya senaryo testleri (Bölüm 4.4), afet yönetimi için en uygun model konfigürasyonunu belirlemek üzere değerlendirilmiştir. Önemli olarak, bu aşamadaki model seçimi tamamen 5-Fold Cross-Validation sonuçlarına ve nitel vaka analizlerine dayanmakta olup, yalnızca bir sonraki bölümde raporlanan nihai değerlendirme için ayrılan held-out Blind Test Set’e hiçbir şekilde

başvurulmamıştır. Tablo 9’de elde edilen verilere dayanarak, Stacking yönteminin tüm mimarilerde tutarlı biçimde en yüksek veri kalitesini (5-Fold Cross-Validation’da 0.9701 Macro F1) sağladığı doğrulanmıştır. Mimari açıdan, DistilBERT (5-Fold Cross-Validation’da 0.9338 Macro F1) kaynak kısıtlı cihazlar için güçlü bir alternatif olsa da, kritik afet verilerinde maksimum doğruluk hedeflediğimiz için Türkçe dil yapısına en uygun dbmdz/bert-base-turkish-cased mimarisi öne çıkmaktadır. Sonuç olarak, hem 5-Fold Cross-Validation altındaki istatistiksel güvenilirliği (Bölüm 4.3) hem de karmaşık varlıkları tespit etme yeteneği (Bölüm 4.4) kanıtlanan Stacked-BERT-17k modeli, bu çalışmanın nihai modeli olarak seçilmiştir. Bir sonraki bölümde, seçilen bu modelin görülmemiş verilere genellemesini objektif biçimde ölçmek için performansı izole Blind Test Set üzerinde analiz edilecektir.

4.6. Nihai Modellerin Kör Test Kümesinde Değerlendirilmesi

Önceki aşamalarda, 17.000 örneklik veri kümeleriyle eğitilen modeller yaklaşık %97’lik iç tutarlılık skorları elde etmiştir. Ancak bu skorlar, modellerin “Teacher”ları (LLM’ler) tarafından üretilen veriler üzerindeki performansını yansıtmaktadır.

Modelin gerçek dünya performansını ve genelleme yeteneğini objektif biçimde ölçmek için 300 cümlelik bağımsız bir “Blind Test Set” kullanılmıştır. Bu küme, ham veri havuzundan rastgele seçilmiş, eğitim veya model seçimi sırasında hiç görülmemiş ve uzmanlar tarafından etiketlenmiştir. Kritik olarak, Blind Test Set yalnızca bu nihai değerlendirme aşamasında kullanılmıştır; önceki tüm mimari ve ensemble stratejisi kararları 5-Fold Cross-Validation’a (Bölüm 4.3) dayandırılmıştır. Tablo 15, metodolojinin veri ölçekleme yörüngesi (500 Gold $\rightarrow$ 3.000 Silver $\rightarrow$ 17.000 Scaled) boyunca performans evrimini sunmaktadır; burada Stacked-BERT-3k satırı, model seçimi için bir aday olarak değil, bu yörünge üzerinde bir ara referans noktası olarak yer almaktadır.

Table 15: Modellerin 300 Cümlelik ‘Blind Test Set’ Üzerindeki Performans Evrimi

Eğitim Verisi Boyutu	Model Mimarisi	Macro F1
500 (Gold)	Baseline-BERT	0.8476
3,000 (Silver)	Gradient-Boost Stacked-BERT-3k	0.9102
17,000 (Scaled)	Voted-BERT-17k	0.9104
17,000 (Scaled)	Gradient-Boost Stacked-BERT-17k	<u>0.9160</u>

Tablo 15’deki sonuçlar incelendiğinde, 17.000 verilik sentetik kümelerle eğitilen her iki modelin de %91’in üzerinde Macro F1 skorları elde ederek birbirine çok yakın ve rekabetçi bir performans sergilediği görülmektedir. Bu sonuç, yalnızca 500 veriyle eğitilen ve aynı Blind Test Set üzerinde değerlendirilen Baseline modelin performansına (0.8476) kıyasla yaklaşık %8’lik anlamlı bir iyileşmeye işaret etmektedir. Bu 0.8476’nın, doğrudan Blind Test Set üzerinde değerlendirilen Baseline-BERT’e karşılık geldiğini, Tablo 6’de raporlanan 0.8335’in ise aynı mimarının 500 tweet’lik Gold kümesi üzerindeki 5-Fold Cross-Validation sonucunu ifade ettiğini belirtmek gerekir; dolayısıyla iki değer bir tutarsızlığı değil, farklı değerlendirme protokollerini yansıtmaktadır. Nihai ölçeklenmiş modeller birbirleriyle karşılaştırıldığında, Gradient-Boost Stacked-BERT-17k modeli (0.9160), Voted-BERT-17k modelini (0.9104) hafifçe geride bırakmış ve Gradient-Boost Stacking tabanlı veri üretim yönteminin marjinal bir avantajına işaret etmiştir; bu avantaj, sonraki bootstrap analiziyle daha ayrıntılı olarak nicelleştirilmektedir.

Gözlemlenen farkların istatistiksel olarak güvenilir olup olmadığını değerlendirmek için, 300 tweet’lik Blind Test Set üzerinde, değerlendirme metriği olarak varlık düzeyi Macro F1 (sekeval) kullanılarak 1000 yeniden örnekleme iterasyonlu eşleştirilmiş bootstrap testi yapılmıştır. Üç Student modelin de Baseline-BERT’e göre iyileşmeleri istatistiksel olarak anlamlıdır ($p < 0.01$); buna karşın Student modellerin kendi aralarındaki farklar istatistiksel anlamlılığa ulaşmamaktadır (Stacked-BERT-17k - Voted-BERT-17k: $p = 0.13$; Stacked-BERT-17k - Stacked-BERT-3k: $p = 0.36$). Tüm ikili karşılaştırmalar için etki büyüklükleri ve %95 güven aralıkları Tablo 16’de raporlanmaktadır. Bu bulgular, önerilen hatta atfedilebilir temel performans kazanımının, Stacking ile Voting birleştirmesi arasındaki veya 3.000 ile 17.000 örnekli ölçekleme arasındaki spesifik tercih değil, manuel etiketli Gold veriden LLM tarafından üretilen Silver/Scaled veriye geçiş olduğunu göstermektedir. Kritik biçimde bu durum, gözlemlenen iyileşmenin etiket kalitesinden değil yalnızca artan eğitim kümesi boyutundan kaynaklanabileceği endişesini de doğrudan ele almaktadır: eğitim verisini 3.000’den 17.000 örneğe yaklaşık altı kat ölçeklemek istatistiksel olarak anlamlı bir kazanç sağlamazken (Stacked-BERT-3k - Stacked-BERT-17k, $p = 0.36$, Tablo 16), belirleyici ve istatistiksel olarak anlamlı sıçrama, miktarın değil etiket kalitesinin değiştiği Gold→Silver geçişinde gerçekleşmektedir. Bu ayrışma, performans kazanımının ham veri hacminden ziyade LLM tarafından üretilen etiketlerin semantik kalitesinden kaynaklandığını göstermektedir.

Table 16: 300 Tweet’lik Blind Test Set Üzerinde Eşleştirilmiş Bootstrap Anlamlılık Testleri (1000 yeniden örnekleme iterasyonu, varlık düzeyi Macro F1)

Karşılaştırma	Δ Macro F1	Δ ’nın %95 GA’sı	p -değeri
Stacked-BERT-17k vs Baseline-BERT	+0.0462	[+0.0330, +0.0599]	< 0.01
Voted-BERT-17k vs Baseline-BERT	+0.0407	[+0.0265, +0.0549]	< 0.01
Stacked-BERT-3k vs Baseline-BERT	+0.0430	[+0.0296, +0.0572]	< 0.01
Stacked-BERT-17k vs Stacked-BERT-3k	+0.0032	[−0.0031, +0.0102]	0.36
Stacked-BERT-17k vs Voted-BERT-17k	+0.0055	[−0.0013, +0.0128]	0.13

4.6.1. Varlık Bazlı Performans Analizi

Modellerin başarısını daha ayrıntılı incelemek için, her iki modelin performans raporları varlık türlerine (LOC, PER, ORG, NEED vb.) göre karşılaştırılmıştır. Afet veri kümesindeki doğal sınıf dengesizliğine dikkat etmek önemlidir; ‘LOC’ (Support: 677) ve ‘NEED’ (Support: 508) varlıkları, ‘LINK’ (Support: 110) veya ‘PHONE’ (Support: 213) gibi sınıflardan belirgin ölçüde daha baskındır. Ancak geleneksel yeniden örnekleme teknikleri (ör. oversampling veya undersampling) kullanılmamıştır. BERT gibi Transformer tabanlı mimariler, yapay veri manipülasyonuna gerek kalmadan azınlık sınıflarının semantik yapısını yakalayan çift yönlü attention mekanizmaları ve derin bağlamsal embedding’leri sayesinde bu tür dengesizlikleri doğal olarak etkili biçimde ele almaktadır. Ayrıca baskın sınıfların genel değerlendirmeyi çarpıtmasını önlemek için, tüm sınıflardaki model performansı basit doğruluk yerine öncelikle ‘Macro F1’ ve ‘Weighted F1’ skorlarıyla değerlendirilmiştir. Projenin en başarılı modeli olan Stacked-BERT-17k’nın sınıf bazlı metrikleri Tablo 17’de sunulmaktadır. Sınıflandırma raporları Entity-Level’da tam eşleşmeleri değerlendirirken (toplam 2.182 support ile sonuçlanmaktadır), sonraki confusion matrix’lerin BIO etiket sınırı karışıklıklarına ilişkin ayrıntılı içgörü sağlamak amacıyla Token-Level’da üretildiğini belirtmek gerekir.

Table 17: Stacked-BERT-17k Modelinin Ayrıntılı Sınıflandırma Raporu (Entity-Level)

Varlık	Precision	Recall	F1-Score	Support
LINK	1.0000	1.0000	1.0000	110
LOC	0.8777	0.9010	0.8892	677
NEED	0.8501	0.9154	0.8815	508
ORG	0.9150	0.9059	0.9104	404
PER	0.8981	0.8815	0.8897	270
PHONE	0.9505	0.9014	0.9253	213
Macro Avg	0.9152	0.9175	0.9160	2182
Weighted Avg	0.8940	0.9079	0.9005	2182

Karşılaştırma amacıyla, Voted-BERT-17k modelinin tüm sınıfları kapsayan ayrıntılı raporu Tablo 18’de sunulmaktadır.

Table 18: Voted-BERT-17k Modelinin Ayrıntılı Sınıflandırma Raporu (Entity-Level)

Varlık	Precision	Recall	F1-Score	Support
LINK	1.0000	1.0000	1.0000	110
LOC	0.8752	0.8907	0.8829	677
NEED	0.8526	0.8996	0.8755	508
ORG	0.9443	0.9233	0.9337	404
PER	0.8433	0.8370	0.8401	270
PHONE	0.9554	0.9061	0.9301	213
Macro Avg	0.9118	0.9095	0.9104	2182
Weighted Avg	0.8929	0.8992	0.8958	2182

Tablo 17 ve Tablo 18 karşılaştırıldığında, her iki modelin de tüm varlık sınıflarında güçlü ve rekabetçi bir performans sergilediği görülmektedir. Stacked-BERT-17k modeli, özellikle afet yönetiminde kritik olan sınıflarda avantaj sağlamaktadır:

LOC (Konum): Stacked model 0.8892, voted model ise 0.8829 F1 skoruna sahiptir. Stacking, lojistik planlama için kritik olan konum tespitinde hafif bir iyileşme sağlamıştır.

NEED (İhtiyaç): Stacked model 0.8815, Voted model ise 0.8755 F1 skoruna sahiptir. Daha da önemlisi, Stacked modelin Need sınıfındaki Recall oranı 0.9154 iken Voted modelinki 0.8996’dır. Bu 0.0158’lik fark, Stacked

modelin afet yardım çağrılarını kaçırma (False Negative) riskini hafifçe azalttığını göstermektedir.

PER (Kişi): Stacked model (0.8897), kişi adlarının tespitinde Voted modelden (0.8401) belirgin biçimde daha başarılı olmuş ve afetzede kimliklendirme sürecine daha fazla katkı sağlamıştır. Bu 0.0496’lık iyileşme, Stacking yönteminin sınıf bazındaki en büyük avantajını temsil etmektedir.

ORG (Kurum): İlginç biçimde, kurum tespitinde Voted model (0.9337), Stacked modeli (0.9104) 0.0233 farkla geride bırakmıştır. Bu, Voting yönteminin daha basit birleştirmesinin belirli bağlamlarda kurum sınırı örüntülerini daha etkili koruyabileceğine işaret etmektedir.

4.6.2. Hata Analizi ve Confusion Matrix’ler

Modellerin genel başarısının ötesinde, hangi varlık türlerini birbiriyle karıştırdıklarını ve adres tutarlılığını ne kadar iyi koruduklarını anlamak, sistemin güvenilirliği için kritiktir. Bu amaçla, Stacked-BERT-17k ve Voted-BERT-17k modellerinin varlık sınıfları bazındaki tahmin dağılımları, Confusion Matrix’ler kullanılarak karşılaştırmalı olarak incelenmiştir.




Figure 4: Nihai Modellerin Confusion Matrix’leri (Token-Level)

Projenin nihai modeli olan Stacked-BERT-17k’nın sonuçları Şekil 4a’de sunulmaktadır. Matris incelendiğinde, modelin I-LOC etiketini 1.368 kez doğru tanımladığı, adres sınırlarını belirlemede (boundary detection) ve çok kelimeli konumları bütün olarak yakalamada Voted modele üstünlük sağladığı görülmektedir. Daha da önemlisi, disaster response için en kritik class olan

B-NEED label'ı için, Stacked model Voted model'e (485) kıyasla 489 doğru tespit elde etmiş olup, bu fark istatistiksel olarak anlamlı olmamasına rağmen yardım çağrılarını yakalamada marjinal bir avantaj göstermektedir (bkz. Tablo 16).

Şekil 4b'de sunulan matris incelendiğinde, Voted modelin adres takibi için kritik olan I-LOC (Konum Devamı) etiketini 1.351 kez doğru tahmin ettiği, ancak B-NEED (İhtiyaç Başlangıcı) etiketinde yalnızca 485 doğru tahmin yaptığı görülmektedir. Dikkat çekici biçimde, 21 I-LOC token'ı yanlışlıkla B-LOC olarak tahmin edilmiş ve 13 I-ORG token'ı I-LOC olarak yanlış sınıflandırılmış olup bu, varlık sınırlarını korumadaki zorluklara işaret etmektedir.

İki matris karşılaştırıldığında, Stacked-BERT-17k modeli hem I-LOC (1.368'e karşı 1.351) hem de B-NEED (489'a karşı 485) tahminlerinde tutarlı iyileşmeler göstermiştir. Ancak Voted model, gerçekte I-ORG olan yalnızca 13 token'ın yanlışlıkla I-LOC olarak tahmin edildiği I-ORG (Kurum Devamı) sınıfında daha düşük bir karışıklık oranı sergilemiştir; Stacked modelde bu tür hataların sayısı 22'dir. Bu durum, hem bir Kurum (ORG) hem de fiziksel bir Konum (LOC) belirten "Hatay Devlet Hastanesi" veya "Afet Koordinasyon Merkezi" gibi ifadelerden kaynaklanan semantik belirsizliğin bir sonucudur. Bununla birlikte, Stacked modelin B-NEED ve I-LOC sınıflarındaki belirgin iyileşmesi, bu küçük semantik kaymayı tolere edilebilir kılmakta ve Stacked yöntemin afet verilerindeki dayanıklılığını göstermektedir.

4.7. *State-of-the-Art ile Karşılaştırma*

Önerilen "veri merkezli" yaklaşımı daha geniş bir metodolojik perspektiften değerlendirmek amacıyla, elde edilen sonuçlar Türkçe NER literatüründeki güncel çalışmalarla karşılaştırılmıştır. Karşılaştırma sonuçları Tablo 19'de sunulmaktadır.

Table 19: State-of-the-Art Türkçe NER Çalışmalarıyla Karşılaştırma[†]

Çalışma	Alan	Yöntem	Veri Kaynağı	F1 (Raporlanan)	Not
Bizim Çalışmamız (Stacked-BERT-17k)	Afet	Stacking + Pseudo-Labeling	Sentetik (Otomatik Etiketli)	0.9160	Macro F1
TMD-NER [17]	Sosyal Medya	BiLSTM-CRF	121k Tweet (Manuel)	0.8400	Yüksek İnsan Emeli
Akali vd. [16]	Medikal	LLM Prompting	Many-Shot Örnekler	0.8400	Exact Match (Relaxed: 0.99)
Khudoyberdieva [15]	Genel	XLM-R	Wikipedia Infobox'ları	0.9334	Genel Alan Baseline'ı

[†] Sonucumuz Macro F1 olarak raporlanmıştır. Karşılaştırma çalışmalarının skorları, F1 türü bu çalışmalarda tek tip belirtilmediğinden, orijinal makalelerin raporladığı metrikleri yansıtmaktadır.

Tablo 19, Türkçe NER literatüründeki farklı yaklaşımların performansını göstermektedir. TMD-NER'in [17] genel, büyük ölçekli bir sosyal medya veri kümesi üzerinde çalıştığı, modelimizin ise oldukça spesifik ve gürültülü bir afet alanına odaklandığı düşünüldüğünde, çalışmamız ile TMD-NER arasında doğrudan bir performans karşılaştırmasının tamamen basit olmadığını belirtmek önemlidir. Bu nedenle bu karşılaştırmanın amacı, kesin bir benchmark olmaktan ziyade metodolojiktir. TMD-NER, akut acil durumlarda operasyonel olarak uygulanamaz bir süreç olan 121.310 verinin devasa manuel etiketleme çabasını gerektirerek 0.8400 F1 skoru elde ederken, önerdiğimiz metodoloji yalnızca 500 manuel etiketli çekirdek veriden üretilen sentetik verilerle kendi alanında son derece rekabetçi bir 0.9160 Macro F1 skoruna ulaşmıştır. Bu, yaklaşımımızın veri verimliliğini ve hızlı devreye alma kapasitesini öne çıkarmakta; önerilen Data-Centric metodolojinin zaman açısından kritik kriz senaryoları için yalnızca bir alternatif değil, hayati bir zorunluluk olduğunu kanıtlamaktadır.

Ayrıca Akali et al. [16], medikal alanda LLM'leri doğrudan kullanarak (Prompting) 'Exact Match' için 0.84 F1 skoru elde etmiştir. LLM tarafından üretilen pseudo-label'larla eğitilen Student modelimiz (BERT), devasa LLM'lere kıyasla çok daha küçük bir mimariye sahip olmasına rağmen 0.9160 Macro F1 skoru elde ederek yüksek kaliteli sentetik verinin, hafif modellerin doğrudan LLM prompting'in exact match başarısına ulaşmasını veya bunu aşmasını sağlayabildiğini göstermiştir. Bu, üretim ortamlarında dağıtım için çok daha maliyet-etkin bir alternatif sunmaktadır. Son olarak Khudoy-

berdieva and Diri [15], Wikipedia gibi iyi yapılandırılmış metinler ve zayıf denetimli (infobox) verilerle 0.9334 skoru elde ederek genel alan için bir üst sınır belirlemiştir. Afet metinleri yüksek düzeyde gürültü ve yapısal düzensizlik içermesine rağmen, veri merkezli yaklaşımımız bu genel alan baseline'ına oldukça yaklaşılarak dayanıklılığını doğrulamaktadır.

Sentetik bir baseline oluşturmak için 500 Gold örnek üzerinde geleneksel data augmentation tekniklerini (ör. eşanlamlı değiştirme veya back-translation) bilinçli olarak kullanmadığımızı belirtmek gerekir. Ye et al. [29] tarafından ampirik olarak gösterildiği üzere, eşanlamlı değiştirme veya segment karıştırma [30] gibi NER için basit veri artırma yöntemleri, sıklıkla semantik bütünlüğü bozmakta ve token-etiket hizalamasını aksatmaktadır. Buna karşın LLM tabanlı veri üretimi, büyük dil modellerine gömülü dünya bilgisinden yararlanarak daha yüksek kaliteli ve daha çeşitli eğitim örnekleri üretmektedir [29]. Birden fazla NER benchmark'ı üzerindeki deneyleri, LLM tarafından üretilen artırılmış verinin özellikle few-shot senaryolarında geleneksel yöntemlerden tutarlı biçimde daha iyi performans gösterdiğini doğrulamaktadır. Metodolojimiz bu paradigmayla uyumludur: aynı 500 örneği gürültü ekleme riski taşıyan yüzeysel dönüşümlerle yeniden kullanmak yerine, ham veri havuzundan daha önce görülmemiş 17.000 tweet'i etiketlemek için frontier LLM'lerden yararlanmakta ve basit veri artırmanın kopyalayamayacağı gerçek dünya sözcüksel çeşitliliğini yakalamaktayız.

4.8. Teorik Çıkarımlar: Data-Centric AI Paradigma Değişimi

Önerilen Teacher-Student mimarisinin başarısı, yapay zeka alanındaki temel bir evrimin altını çizmektedir: model merkezli geliştirmeden veri merkezli geliştirmeye geçiş. Geleneksel olarak performans kazanımları, model karmaşıklığını artırma yoluyla aranmıştır; ancak sonuçlarımız, modern ve ölçeklenebilir yapay zekanın özünün, eğitim verisinin semantik kalitesine ve zenginliğine öncelik vermekte yattığını göstermektedir.

Frontier LLM'lerden (Gemini, Claude ve GPT) oluşan bir Stacking ensemble kullanarak yalnızca etiketlemeyi otomatikleştirmedik; milyarlarca parametrenin kolektif akıl yürütme gücünden etkin biçimde yararlanarak 'manuel kürasyon darboğazını' aştık. Bu stratejik dönüşüm, sınırlı 500 tweet'lik bir gold kümeyi devasa, 17.000 tweet'lik yüksek kaliteli bir ekosisteme dönüştürmemizi sağlamıştır. LLM'lerin otomatik, uzman düzeyinde bir etiketleme motoru olarak kullanılması, zaman açısından kritik kriz senaryolarında devasa modellerin 'örtük zekasının' Teacher tarafından üretilen pseudo-label'lar aracılığıyla özelleşmiş student ağlara aktarılmasının geleneksel data augmentation'dan

çok daha etkili olduğunu kanıtlamaktadır. Bu yaklaşım, yüksek kaliteli, LLM tarafından üretilen pseudo-labeled verinin model genellemesi için nihai katalizör olduğunu doğrulamakta ve düşük kaynaklı ortamlarda yüksek performanslı sistemlerin hızla devreye alınması için yeni bir şablon oluşturmaktadır.

5. Sonuç ve Gelecek Çalışmalar

Bu çalışma, 6 Şubat 2023 Türkiye-Suriye depremlerinin ardından Türkçe afet yönetimindeki etiketli veri kıtlığı gibi kritik bir darboğazı özel olarak ele alan, Large Language Model’leri (LLM) ve Ensemble tekniklerini bütünleştiren yenilikçi, uçtan uca bir ‘Data-Centric Artificial Intelligence’ mimarisi sunmaktadır. Geleneksel model merkezli yaklaşımların aksine bu araştırma, veri kalitesini ve miktarını artırmaya odaklanmaktadır. Yalnızca 500 örneklik sınırlı bir manuel veri kümesinden başlayarak, 20.000 etiketsiz tweet’lik bir ham havuzu işleyerek manuel insan müdahalesine gerek kalmadan devasa, yüksek kaliteli eğitim derlemleri (3.000 Silver ve 17.000 Scaled örnek) başarıyla üretmiştir. Deneysel bulgular, Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5 modellerinin kolektif zekasını kullanan Stacking Ensemble yönteminin, hem bireysel modellerden hem de geleneksel yöntemlerden üstün, 0.9313 Macro F1 skoruyla (sızıntısız tweet düzeyi GroupKFold altında 0.9219) önemli bir ‘Teacher’ performansı elde ettiğini göstermektedir. Bu teacher tarafından üretilen pseudo-label’larla eğitilen nihai student model (Stacked-BERT-17k), görülmemiş 300 cümlelik bir Blind Test Set üzerinde 0.9160 Macro F1 skoru elde etmiştir. TMD-NER (121.310 örnek) gibi genel alan çalışmalarında görülen devasa manuel etiketleme çabalarını gerektirmek yerine, yaklaşımımız veri darboğazını başarıyla aşarak Türkçe gibi morfolojik açıdan karmaşık diller için son derece veri-verimli bir alternatif sunmuştur. Ayrıca, yüksek kaliteli sentetik verinin, hafif modellerin doğrudan, yüksek maliyetli LLM prompting’in exact match başarısına ulaşmasını veya bunu aşmasını sağlayabildiğini göstermekte ve nihayetinde hızlı afet müdahalesi için tasarlanmış, son derece ölçeklenebilir ve “maliyet-etkin” bir çözüm sunmaktadır.

Elde edilen başarılı sonuçlara rağmen çalışmanın bazı sınırlılıkları bulunmaktadır. Öncelikle, gelişmiş ‘Teacher’ modellerin (GPT-5, Claude Sonnet 4.5, Gemini 2.5 Pro) yüksek API maliyetleri, üçlü LLM ensemble’ın büyük ölçekli veri kümelerine doğrudan uygulanmasına pratik bir üst sınır getirmektedir. 17.000 örneğin tamamını doğrudan tam Stacking ensemble ile etiketlemek gibi naif bir yaklaşım, tahmini \$724’ün üzerinde bir maliyet gerektirecek-

tir. Ancak önerilen iki aşamalı metodoloji bu kısıtı özel olarak ele almaktadır: üçlü LLM ensemble önce yalnızca temsili 3.000 örneklik Silver kümeye uygulanmakta (toplam yaklaşık \$127.79'luk API maliyetiyle), ardından pseudo-label ile eğitilmiş Student model, kalan 17.000 örnek için sıfır maliyetli bir proxy etiketleyici olarak kullanılmakta ve metodoloji, doğrudan etiketleme maliyetinin yaklaşık altıda biriyle karşılaştırılabilir nihai performans elde etmektedir. Dolayısıyla bu maliyet verimliliği yalnızca bir geçici çözüm değil, önerilen Data-Centric hattın temel bir tasarım ilkesidir. Ayrıca çalışma yalnızca metin tabanlı verilere (tweet'ler) odaklanmış; afetlerde sıkça paylaşılan enkaz görüntüleri veya ses kayıtları kapsam dışında bırakılmıştır. Ek olarak, sosyal medya dilinin dinamik doğası (yazım hataları, ironi ve internet jargonu) süregelen zorluklar oluşturmaktadır. Son olarak, önemli bir sınırlılık veri kümesinin kapsamında yatmakta olup *Domain Adaptation*'a yönelik kritik ihtiyacı vurgulamaktadır. Önerilen veri merkezli metodoloji, depreme özgü terminolojiyi çıkarmada son derece etkili olduğunu kanıtlamış olsa da, gelecekteki araştırmaların yöntemin sel veya orman yangını gibi diğer doğal afet türlerine uygulanabilirliğini titizlikle test etmesi ve uyarlaması gerekmektedir.

Gelecekteki araştırmalar, bu maliyet kısıtını yerel sunucularda eğitilen daha küçük, açık kaynak LLM'leri teacher olarak kullanarak aşmayı ve metin tabanlı analizi görsel öğelerle destekleyen multimodal sistemler geliştirmeyi hedeflemektedir. Ayrıca, model tarafından düşük güvenle tahmin edilen verilerin otomatik olarak tespit edilip insan uzman onayına sunulduğu "human-in-the-loop" aktif öğrenme mekanizmalarının entegrasyonu, sistemin zamanla kendini iyileştirmesini sağlayacaktır. Nihayetinde bu araştırma, manuel etiketleme maliyetini ortadan kaldırarak afetlerde saniyeler içinde devreye alınabilecek hayat kurtarıcı bir teknolojik çözüm sunmaktadır.

Finansman

Bu çalışma, Bursa Uludağ Üniversitesi Bilim ve Teknoloji Merkezi (BAP) tarafından FGA-2026-2534 numaralı hibe kapsamında desteklenmiştir.

Üretken Yapay Zeka Kullanım Beyanı

Yazar(lar), frontier modellerin (Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5) metodolojide detaylandırıldığı üzere yalnızca veri etiketleme için

deneysel bileşenler (Teacher modeller) olarak kullanıldığını beyan etmektedir. Bu makalenin hazırlanmasında, yalnızca küçük çaplı dil düzenlemesi ve LaTeX biçimlendirme yardımı için tamamen ayrı ve izole bir Claude (Anthropic) örneği kullanılmıştır. Yazarlar, editoryal yardım için kullanılan yapay zekanın deneysel hat veya veri üretimi üzerinde hiçbir erişimi veya etkisi olmadığını teyit etmektedir.

Veri Erişilebilirliği

Bu çalışmada kullanılan veri kümesi, afetten etkilenen bireylere ait hassas kişisel bilgiler (isimler, adresler, telefon numaraları) içerdiğinden gizlilik gerekçesiyle kamuya açık olarak paylaşılammamaktadır. Anonimleştirilmiş örnek veriler ve kod, makul talep üzerine sorumlu yazardan temin edilebilir.

Appendix A. LLM Etiketleme Prompt Şablonu

Tekrarlanabilirliği sağlamak amacıyla, Gemini 2.5 Pro, Claude Sonnet 4.5 ve GPT-5 modelleri için kullanılan tam sistem prompt'u aşağıda verilmektedir. Prompt, aşağıdaki temel bileşenlerden ve orijinal Türkçe şablondan oluşmaktadır.

PROMPT BİLEŞENLERİ VE YÖNERGELER

- **Rol Tanımı:** Modele, Türkçe afet ve acil durum tweet'lerinde uzmanlaşmış, son derece hassas bir NER uzmanı olarak davranması talimatı verilir.
- **Temel İlke:** Anlam biçimden üstündür - token'lar, yüzey işaretlerine (@ veya #) göre değil, semantik anlamlarına ve cümledeki işlevlerine göre etiketlenmelidir.
- **Girdi/Çıktı Kuralları:** Model, token'lardan oluşan bir Python listesi alır ve ek metin olmaksızın yalnızca şu formatta bir JSON nesnesi döndürmelidir: {"ner_tags": [ID listesi]}.
- **Varlık Yönergeleri:** Her varlık türü için ayrıntılı talimatlar:
 - **O (ID: 0):** Tematik hashtag'ler ve ünlü mention'ları dahil varlık dışı token'lar

- **PER (ID: 1-2):** Yalnızca yardıma muhtaç veya enkaz altındaki kişiler
 - **LOC (ID: 3-4):** Konum belirten hashtag'ler dahil coğrafi konumlar
 - **PHONE (ID: 5-6):** Telefon numaraları
 - **NEED (ID: 7-8):** Somut fiziksel ihtiyaçlar veya kaynaklar
 - **ORG (ID: 9-10):** Kurumsal @mention'lar ve hashtag'ler dahil kurumlar
 - **LINK (ID: 11):** URL'ler (yalnızca B-LINK)
- **Örnekler:** Adres devamlılığı, PER-ORG ayrımı, konum hashtag'leri, çok kelimeli varlıklar ve uç durumları gösteren 14 açıklamalı örnek.

ORİJİNAL SİSTEM PROMPT'U (TÜRKÇE):

Sen, Türkçe afet ve acil durum tweet'leri için özel olarak eğitilmiş, son derece hassas bir NER (Named Entity Recognition) uzmanısın. Senin tek görevin, sana verilen token listesini, aşağıda tanımlanan varlık (entity) türlerine göre etiketlemek ve sonucu belirli bir JSON formatında sunmaktır.

EN ÖNEMLİ KURAL: Anlam Biçimden Üstündür

Etiketlemeyi asla bir token'ın @ veya # ile başlamasına göre yapma. Her zaman token'ın ne anlama geldiğine ve cümledeki işlevine odaklan: Bu yardıma muhtaç bir kişi mi? Yardım edebilecek bir kurum mu? Yoksa sadece bir konu başlığı mı?

GİRDİ & ÇIKTI KURALLARI

1. **Girdi:** Sana her zaman `tokens` olarak adlandırılan bir Python listesi verilecek.
2. **Çıktı:** Yanıtın **kesinlikle ve sadece** aşağıdaki JSON yapısında olmalıdır. Bu JSON, SADECE etiket listesini içermelidir. Öncesinde veya sonrasında hiçbir açıklama, selamlama veya metin ekleme.

```
{
  "ner_tags": "[<her token için ilgili sayısal ID>]"
}
```

3. Token sayısı ile etiket sayısı (döndürdüğü listedeki) bire bir aynı olmalıdır.

ÖRNEK UYGULAMALAR

- **Örnek 1 (Adres Bütünlüğü):**
Girdi: ['İnönü', 'caddesi', 'Rana', 'apartmanı']
Beklenen Etiketler (ID): [3, 4, 4, 4]
- **Örnek 2 (PER ve ORG Ayrımı):**
Girdi: ['@haluklevent', 've', '@ahbap', 'yardım', 'istiyor', '.']
Beklenen Etiketler (ID): [0, 0, 9, 0, 0, 0]
- **Örnek 3 (Mağdur ve Hedef Ayrımı):**
Girdi: ['Adres', ':', '@ayse_yzc', 'için', '@haluklevent', 'yardım', '.']
Beklenen Etiketler (ID): [0, 0, 1, 0, 0, 0, 0]
- **Örnek 4 (Konum Belirten Hashtag):**
Girdi: ['Lütfen', '#hatay', 've', '#samandağ', 'destek', '.']
Beklenen Etiketler (ID): [0, 3, 0, 3, 0, 0]
- **Örnek 5 (Tek Kelimelik NEED):**
Girdi: ['Acil', '#bebekbezi', 've', 'su', 'lazım', '.']
Beklenen Etiketler (ID): [0, 7, 0, 7, 0, 0]
- **Örnek 6 (Çok Kelimeli NEED - 'yardım tırı'):**
Girdi: ['Bölgeye', 'acil', 'yardım', 'tırı', 'gerekıyor', '.']
Beklenen Etiketler (ID): [0, 0, 7, 8, 0, 0]
- **Örnek 7 (Tematik Hashtag'in 'O' Olması):**
Girdi: ['#depem', 'bölgesinde', '#acil', 'yardım', 'lazım', '.']
Beklenen Etiketler (ID): [0, 0, 0, 0, 0, 0]
- **Örnek 8 (Bağlayıcı Kelimelerle Adres Bütünlüğü):**
Girdi: ['Hatay', 'Kırıkhan', 'a', 'bağlı', 'Narlıhöpür', 'Deliçay', 'Köyleri']
Beklenen Etiketler (ID): [3, 4, 4, 4, 4, 4, 4]

- **Örnek 9 (Çok Kelimeli NEED Varlıkları):**
Girdi: ['Acil', 'gıda', 'yardımı', ',', 'erzak', 'yardımı', 've', 'insani', 'yardım', 'malzemesi', 'lazım', '.']
Beklenen Etiketler (ID): [0, 7, 8, 0, 7, 8, 0, 7, 8, 8, 0, 0]
- **Örnek 10 (Tek Kelimeli NEED - 'barınma'):**
Girdi: ['En', 'büyük', 'ihtiyaç', 'barınma', 've', 'yardım', 'çadırı', '.']
Beklenen Etiketler (ID): [0, 0, 0, 7, 0, 7, 8, 0]
- **Örnek 11 (Bitişik Yazılmış Konum Hashtag'leri):**
Girdi: ['Lütfen', '#adıyamandeprem', 've', '#hatayyardımbekliyor', 'için', 'destek', '.']
Beklenen Etiketler (ID): [0, 3, 0, 3, 0, 0, 0]
- **Örnek 12 (Genel Konumların 'O' Olması):**
Girdi: ['Tüm', 'ülkemiz', 'için', 'geçmiş', 'olsun', '.']
Beklenen Etiketler (ID): [0, 0, 0, 0, 0, 0]
- **Örnek 13 (PER ve 'ailesi' Kelimesinin Etiketlenmesi):**
Girdi: ['Meral', 'Bulut', 've', 'ailesi', 'göçük', 'altında', '.']
Beklenen Etiketler (ID): [1, 2, 2, 2, 0, 0, 0]
- **Örnek 14 (Kurum Adları ve @mention'ları):**
Girdi: ['Lütfen', 'Hacettepe', 'Hastanesi', 've', '@pinciTV', 'ile', 'iletişime', 'geçin', '.']
Beklenen Etiketler (ID): [0, 9, 10, 0, 9, 0, 0, 0, 0]

Tüm örnekleri ve ayrıntılı yönergeleri içeren tam prompt, etiketleme sürecimizin birebir kopyalanabilmesini kolaylaştırmak amacıyla ek materyal olarak sunulmaktadır.

References

- [1] C. Hu, X. Li, D. Liu, H. Wu, X. Chen, J. Wang, X. Liu, Teacher-student architecture for knowledge distillation: A survey (2023). URL: <http://arxiv.org/abs/2308.04268>.

- [2] C. Liu, Y. Kang, F. Zhao, K. Kuang, Z. Jiang, C. Sun, F. Wu, Evolving knowledge distillation with large language models and active learning (2024). URL: <http://arxiv.org/abs/2403.06414>.
- [3] M. Xia, H. Wang, Y. Li, Z. Yu, J. Wang, J. Zhao, R. Wu, Prompt candidates, then distill: A teacher-student framework for llm-driven data annotation (2025). URL: <http://arxiv.org/abs/2506.03857>.
- [4] J. Zhao, W. Zhao, A. Drozdov, B. Rozonoyer, M. A. Sultan, J.-Y. Lee, M. Iyyer, A. McCallum, Multistage collaborative knowledge distillation from a large language model for semi-supervised sequence generation (2024). URL: <http://arxiv.org/abs/2311.08640>.
- [5] G. Hinton, O. Vinyals, J. Dean, Distilling the knowledge in a neural network, in: NIPS Deep Learning and Representation Learning Workshop, 2015. URL: <https://arxiv.org/abs/1503.02531>.
- [6] P. West, C. Bhagavatula, J. Hessel, J. D. Hwang, L. Jiang, R. Le Bras, X. Lu, S. Welleck, Y. Choi, Symbolic knowledge distillation: from general language models to commonsense models, in: Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2022, pp. 4602–4625. doi:10.18653/v1/2022.naacl-main.341.
- [7] P. Saxena, S. Janzen, W. Maaß, Streamlining llms: Adaptive knowledge distillation for tailored language models, volume 4, Proceedings of the 2025 Conference of the North American Chapter of the Association for Computational Linguistics: Student Research Workshop, 2025, pp. 448–455. doi:10.18653/v1/2025.naacl-srw.43.
- [8] T. Deußner, M. Hahnbüch, T. Uelwer, C. Zhao, C. Bauckhage, R. Sifa, Resource-efficient anonymization of textual data via knowledge distillation from large language models, in: Proceedings of the 17th International Conference on Agents and Artificial Intelligence (ICAART), 2025, pp. 243–250.
- [9] Y. Li, R. Ramprasad, C. Zhang, A simple but effective approach to improve structured language model output for information extraction (2024). URL: <http://arxiv.org/abs/2402.13364>.

- [10] C. S. Lin, C. N. Tsai, J. S. Jwo, C. H. Lee, X. Wang, Heterogeneous student knowledge distillation from bert using a lightweight ensemble framework, *IEEE Access* 12 (2024) 33079–33088. doi:10.1109/ACCESS.2024.3372568.
- [11] Y. Xiao, J. Song, Y. Xu, R. Zhang, Y. Xiao, X. Lu, R. Zhu, B. Jiang, J. Zhao, El4ner: Ensemble learning for named entity recognition via multiple small-parameter large language models (2025). URL: <http://arxiv.org/abs/2505.23038>.
- [12] S. Saha, A. Ekbal, Combining multiple classifiers using vote based classifier ensemble technique for named entity recognition, *Data & Knowledge Engineering* 85 (2013) 15–39. URL: <https://www.sciencedirect.com/science/article/abs/pii/S0169023X12000626>. doi:10.1016/J.DATAK.2012.06.003.
- [13] A. Singh, S. Singh, U. S. Tiwary, Enhancing hindi named entity recognition through ensemble learning, in: 2023 10th IEEE Uttar Pradesh Section International Conference on Electrical, Electronics and Computer Engineering, UPCON 2023, Institute of Electrical and Electronics Engineers Inc., 2023, pp. 297–300. doi:10.1109/UPCON59197.2023.10434322.
- [14] C. Çetindağ, B. Yazıcıoğlu, A. Koç, Named-entity recognition in turkish legal texts, *Natural Language Engineering* 29 (2023) 615–642. doi:10.1017/S1351324922000304.
- [15] L. Khudoyberdieva, B. Diri, Fine-grained named entity recognition for turkish, in: 32nd IEEE Conference on Signal Processing and Communications Applications, SIU 2024 - Proceedings, Institute of Electrical and Electronics Engineers Inc., 2024. doi:10.1109/SIU61531.2024.10601064.
- [16] Z. Akcali, H. S. Cubuk, A. Oguz, M. Kocak, A. Farzaliyeva, F. Guven, M. N. Ramazanoglu, E. Hasdemir, O. Altundag, A. M. Agildere, Automated extraction of key entities from non-english mammography reports using named entity recognition with prompt engineering, *Bioengineering* 12 (2025). doi:10.3390/bioengineering12020168.

- [17] S. F. Yilmaz, F. B. Mutlu, I. Balaban, S. S. Kozat, Tmd-ner: Turkish multi-domain named entity recognition for informal texts, *Signal, Image and Video Processing* 18 (2024) 2255–2263. doi:10.1007/s11760-023-02898-0.
- [18] S. Olewniczak, J. Szymański, Gold standard, multi-genre dataset for named entity recognition and linking, *Scientific Data* 12 (2025). doi:10.1038/s41597-025-05274-4.
- [19] J. H. Friedman, Greedy function approximation: A gradient boosting machine, *The Annals of Statistics* 29 (2001) 1189–1232. doi:10.1214/aos/1013203451.
- [20] T. Chen, C. Guestrin, XGBoost: A scalable tree boosting system, in: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, ACM, New York, NY, USA, 2016, pp. 785–794. doi:10.1145/2939672.2939785.
- [21] G. Comanici, E. Bieber, M. Schaeckermann, et al., Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities, *arXiv preprint arXiv:2507.06261* (2025). URL: <https://arxiv.org/abs/2507.06261>.
- [22] Anthropic, System Card: Claude Sonnet 4.5, Technical Report, Anthropic, 2025. URL: <https://www-cdn.anthropic.com/963373e433e489a87a10c823c52a0a013e9172dd.pdf>.
- [23] OpenAI, GPT-5 System Card, Technical Report, OpenAI, 2025. URL: <https://cdn.openai.com/gpt-5-system-card.pdf>, also available as arXiv:2601.03267.
- [24] T. G. Dietterich, Ensemble methods in machine learning, in: *First International Workshop on Multiple Classifier Systems*, Springer, 2000, pp. 1–15.
- [25] S. Schweter, Berturk – bert models for turkish, 2020. URL: <https://zenodo.org/records/3770924>. doi:10.5281/zenodo.3770924.
- [26] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, Bert: Pre-training of deep bidirectional transformers for language understanding, in: *Proceedings of the 2019 Conference of the North American Chapter of the*

Association for Computational Linguistics: Human Language Technologies, 2019. URL: <https://github.com/tensorflow/tensor2tensor>.

- [27] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, V. Stoyanov, Un-supervised cross-lingual representation learning at scale (2020). URL: <http://arxiv.org/abs/1911.02116>.
- [28] V. Sanh, L. Debut, J. Chaumond, T. Wolf, Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter (2020). URL: <http://arxiv.org/abs/1910.01108>.
- [29] J. Ye, N. Xu, Y. Wang, J. Zhou, Q. Zhang, T. Gui, X. Huang, LLM-DA: Data augmentation via large language models for few-shot named entity recognition, in: arXiv preprint arXiv:2402.14568, 2024. URL: <https://arxiv.org/abs/2402.14568>.
- [30] X. Dai, H. Adel, An analysis of simple data augmentation for named entity recognition, in: Proceedings of the 28th International Conference on Computational Linguistics, International Committee on Computational Linguistics, 2020, pp. 3861–3867.