

Türkçe Soru Cevap Metinleri Üzerinden Büyük Dil Modellerinin Performans Analizi

Performance Analysis of Large Language Models on Turkish Question-Answer Texts

Metin BİLGİN¹, Mehmet BOZDEMİR¹, Engin DEMİR²

¹Bilgisayar Mühendisliği, Bursa Uludağ Üniversitesi, ²Milli Savunma Üniversitesi
metinbilgin@uludag.edu.tr, 512231003@ogr.uludag.edu.tr, engin.demir@msu.edu.tr

Özet

Doğal dil işleme alanında en çok çalışılan konulardan biri soru cevap sistemleridir. Son yıllarda, verilen bir metin içerisinde sorulan bir sorunun cevabını bulmak önemli bir hale gelmiştir. Bu çalışmada, Türkçe Tarihi verilerinin olduğu SQuAD 1.1 veri seti kullanılarak büyük dil modelleri üzerinde ince ayar işlemi gerçekleştirilmiştir. Çalışmada 5 farklı büyük dil modeli; “bert-base-uncased”, “bert-base-turkish-cased”, “distilbert-base-multilingual-cased”, “mt5-base” ve “mBart-large-50” kullanılarak ince ayar işlemi gerçekleştirilmiştir. Bert, distilbert modelleri Transformer mimarisinin sadece encoder kısmını kullanırken, “mT5” ve “mBart” gibi modeller ise encoder ve decoder’i birlikte kullanırlardır. Seçilen modellerin çoğunluğunun çok dilli (multilingual) olmasına dikkat edilmiştir. Ayrıca çok dilli olmayan “bert-base-uncased” modelinin de Türkçe veriler üzerindeki başarımına bakılmıştır. Çalışma sonuçlarını değerlendirmek için EM, F1 ve Rouge metrikleri kullanılmıştır. Çalışma sonucunda “mBart” modeli diğer modellere göre daha iyi sonuçlar elde etmeyi başarmıştır.

Abstract

One of the most studied topics in the field of natural language processing is question-answering systems. In recent years, finding the answer to a question asked within a given text has become increasingly important. In this study, a fine-tuning process was conducted on large language models using the SQuAD 1.1 dataset containing Turkish historical data. Five different large language models were fine-tuned in this study: “bert-base-uncased”, “bert-base-turkish-cased”, “distilbert-base-multilingual-cased”, “mt5-base”, and “mBart-large-50”. While BERT and DistilBERT models use only the encoder part of the Transformer architecture, models like mT5 and mBART use both the encoder and decoder. It was ensured that most of the selected models were multilingual. Additionally, the performance of the non-multilingual “bert-base-uncased” model on Turkish data was also examined. To evaluate the study results, EM, F1, and Rouge metrics were used. As a result of the study, the “mBART” model achieved better results compared to the other models.

1.Giriş

Doğal Dil İşleme alanında büyük dil modellerinin geliştirilmesi, son yıllarda büyük bir ivme kazanmış ve metin anlama, soru-cevap ve çeviri gibi çeşitli görevlerde ilerlemelere yol açmıştır. Bu modeller, milyarlarca kelime içeren veri setleri kullanılarak eğitilmekte ve çeşitli görevler için kullanılmaktadır. Büyük dil modellerinin ince-ayar yapılarak kullanıldığı alanlardan biri de Soru-Cevaplama (QA)’dır. QA, insanların sordukları soruları otomatik olarak cevap vermeyi hedefler.

Farsça Soru-Cevaplama veri seti (ParSQuAD) tanıtılan çalışmada, BERT, ALBERT ve mBERT dil modelleri kullanılmıştır. Bu veri setiyle eğitilen ve test edilen dil modelleri Tam Eşleşme (EM) ve F1-Skor metrikleriyle değerlendirilmiştir. Sonuç kısmında ise ALBERT ve mBERT dil modellerinin daha iyi performans gösterdiği belirtilmiştir [1]. Türkçe dili için Soru-Cevaplama alanında büyük dil modelleri karşılaştırılan çalışmada 7 dil modeli karşılaştırılmıştır ve Rouge, arc_challenge vb. metriklerle değerlendirmeler yapılmıştır. Çalışma sonucunda en iyi sonucu trendyol_chat dil modelinin verdiği ve daha objektif çalışmalar için daha büyük veri setlerinin kullanılması gerektiği ifade edilmiştir [2]. UYAP Vergi Usul kanununu kullanarak 355 soru-cevap ikilisi SQuAD 1.1 yapısı şeklinde işaretlenen çalışmada değerlendirme yöntemi olarak BERT dil modeli kullanılmıştır. SQuAD 1.1 ile yapılan deneyler sonrasında cevapsız soruları içeren veriler için SQuAD 2.0 veri seti oluşturulmuş ve deneyler yapılmıştır. F1-Skor ve EM metrikleriyle yapılan değerlendirmeler sonucunda SQuAD 2.0 veri seti yapılan deneylerde %5 oranda iyileştirmeler olduğu gözlemlenmiştir [3]. Almanca, Türkçe ve Çince verilerini içeren MQQA veri seti, SQuAD 2.0 formatında oluşturulmuş ve farklı içeriklere sahip olan bu veri seti üzerinde çeşitli dil modellerinin performansının ölçülmesi amaçlanmıştır. GPT-3.5, Llama 2 ve 3 gibi büyük dil modelleri kullanılan çalışmanın sonuç kısmında büyük dil modelleri ile ince-ayarlı dil modelleri arasındaki performanslarda büyük farklılıkların olduğu belirtilmiştir [4]. SQuAD 2.0 veri setinin makine çevirisiyle SQuAD-TR veri seti kullanılan çalışmada, OpenQA yapısıyla çeşitli dil modelleri karşılaştırılmıştır. Çalışmada yapılan deneyler sonucunda, BM25 tabanlı ve DPR tabanlı OpenQA yönteminin, BERT, XLM-BERT gibi dil modelleriyle yapılan karşılaştırmada, EM puanında %24-32 ve F1-skor puanında %22-29’luk bir performans artışı elde ettiği belirtilmiştir [5]. Türkçe tarih verilerini içeren THQuAD veri setindeki pasajı anlayarak ve bu pasajdan cevabı çıkararak belirli bir soruya cevap vermeyi amaçlayan bu çalışmada BERT, ALBERT ve ELECTRA dil modelleri kullanılarak EM ve F1-Skor metrikleri üzerinde değerlendirmeler yapılmıştır. Çalışma sonucunda ELECTRA dil modelinin, BERT ve ALBERT dil modellerine göre daha iyi sonuçlar verdiği gözlemlenmiştir [6].

Literatürde yapılan çalışmalardan farklı olarak çalışmamızda daha fazla sayıda veri içeren bir soru-cevap veri seti ve tamamıyla BERT ve BERT tabanlı dil modelleri ile değil farklı transformer yapılarına sahip dil modelleri kullanılmıştır. Bu çalışmayla hem Türkçe soru-cevap alanına katkı hem de Türkçe veri setleri üzerinde büyük dil modellerinin kullanımını teşvik etmek amaçlanmıştır.

2. Yöntem


Yaptığımız çalışmada soru cevap sistemi oluşturabilmek amacıyla Transformer mimarisini temel alan BERT, T5 ve BART gibi büyük dil modelleri kullanılmıştır.

2.1.BERT (Bidirectional Encoder Representations from Transformers)

BERT modeli ön eğitilmiş olan ve Google tarafından tasarlanmış büyük bir modelidir. BERT modeli bilindiği üzere ön eğitilmiş olarak 2 farklı görev için eğitilmiştir [7] .

- MLM (Masked Language Model)
- NSP (Next Sentence Prediction)

MLM’de modelin eğitim aşamasında ilgili derlem içindeki maskelenen kelimeleri bulması hedeflenir. Bu şekilde eğitildiğinde derlem içindeki yapıları ve ilişkileri çok iyi analiz edebilir. Özellikle kelimeler arasındaki bağlamı iyi yakalayabilir. Metin özetleme, duygu analizi, metin sınıflandırma, varlık isim tanıma ve soru cevaplama gibi sistemlerde rahat bir şekilde kullanılabilir.



Şekil 1: BERT Modeli [7]

Şekil-1’de görülebileceği üzere model ön eğitilmiş olarak gelmektedir. Her bir cümle içindeki seçilen kelimeler maskelenmektedir. Örneğin “BERT ön eğitilmiş [MASK] modelidir.” şeklindeki bir cümle için model maske yerine gelebilecek olan kelimeyi tahmin etmeyi öğrenir. Bu şekilde model büyük bir veri kümesi ile eğitilir. Ön eğitilmiş modeli alıp kullanmak bazen istediğimiz sonuçları vermeyebilir. Çünkü model genel anlamda büyük bir derlem ile eğitilse de modelin daha önce görmediği bilgileri tahmin etmesi istendiğinde bu sorun teşkil edebilmektedir. Bu noktada modeli ince ayar yaparak kişisel verilerimiz üzerinde eğitiriz. Artık model kişisel verilerimiz için daha tutarlı sonuçlar verebilecektir. Bizim yapacağımız soru cevap sistemleri açısından konuya baktığımızda ise modelin kendisine verilen bir derlem içerisinde, sorulan sorunun doğru cevabını bulması hedeflenmektedir. Burada model yapısı gereği girdi olarak soru ve derlemi almaktadır. Çıktı olarak ise cevabın derlem içerisindeki başlangıç ve bitiş konum bilgisini vermektedir. Aşağıda gösterildiği gibi bir yapı olacaktır.

Context = “F klavye, Türkçe için özel olarak geliştirilmiş bir klavye çeşididir. 20 Ekim 1955 tarihinde Bakanlıklar arası Standardizasyon Komitesi tarafından onaylanmış ve bu tarihten itibaren kullanılmaya başlanmıştır.”

Question= “F Klavye'nin Bakanlıklararası Standardizasyon Komitesi tarafından onaylandığı tarih nedir?”


Answer = “{'answer_start': '11', 'text': '20 Ekim 1955'}”

Cevaba baktığımızda 'answer_start': '11' olduğu görülüyor. Buradan modelin aslında gerçek cevap olan '20 Ekim 1955' adlı metni öğrenmek yerine onun başladığı konum bilgisi ve sonlandığı konum bilgisini öğrendiği görülmektedir. Bu noktadan baktığımızda durumun bu şekilde olması cevabın derlem içerisinde olmasını garanti etmektedir. Dolayısı ile BERT gibi modeller üretken cevap vermek yerine dilin yapısını çok iyi anlayarak derlem içerisinde en iyi tahmini yapmayı amaçlamaktadır.

NSP gibi yapı ise BERT modellerinin cümleler arasındaki ilişkiyi yakalamasında önemli bir rol oynamaktadır. Yani aslında BERT yukarıda bahsettiğimiz MLM ve NSP ile ön eğitilmiş olarak gelmektedir. Bu şekilde model hem kelimeler arasındaki bağlamı hem de cümleler arasındaki bağlamı yakalamaktadır. Bizim yapacağımız bu çalışmada BERT ve BERT tabanlı olan modeller kullanılarak soru-cevap sistemleri üzerindeki performansı değerlendirilmiştir. BERT modeli Transformer modelinin sadece encoder kısmını kullanmaktadır. Buradan olaya baktığımızda model bir derleme bağlı kalarak bir içerik üretecektir. Bu daha doğru ve isabetli sonuçlar vermesini sağlayacaktır. Diğer bir açıdan baktığımızda ise yaratıcı bir sonuç beklemek doğru olmayacaktır. Örneğin GPT, Gemini, Llama gibi modeller Transformer’ın sadece decoder kısmını kullanarak daha yaratıcı sonuçlar vermektedir. Fakat yaptığımız bu çalışmada modelin yaratıcı sonuç vermesinden ziyade doğru sonuçlar vermesini istediğimiz için BERT ve BERT tabanlı modeller kullanılmıştır. Yaratıcı sonuçlar çoğu durumda içerikle alakalı olmayan sonuçlar da üretebilmektedir.

2.2. T5 (Text-To-Text Transfer Transformer)

T5 modeli Transformer mimarisinin encoder ve decoder kısımlarını birlikte kullanan bir yapıdadır. Encoder kısmı BERT’te olduğu gibi çift yönlü çalışırken, decoder kısmı ise otoregresif olarak çalışmaktadır [8]. Daha çok bir metinden diğer bir metne dönüştürme görevlerinde başarılı olarak çalışmaktadır. Soru-cevap, metin özetleme, makine çevirisi, Anlamsal benzerlik, dil bilimsel kabul edilebilirlik gibi görevlerde yaygın olarak kullanılmaktadır. T5 modeli ön eğitilmiş bir model olarak gelmektedir. Yukarıda isimlerini saydığımız birden fazla görev için önceden eğitilmiştir.



Şekil 2: T5 Modeli [8]

Şekil 2’de modelin birden fazla görev için önceden eğitilmiş olduğu görülmektedir. Peki bu modeli kullanmak istediğimizde nasıl bir girdi ile çalışmak gerekecektir. Modeli bir özetleme görevinde kullanmak istiyorsanız modele verdiğiniz girdinin başında bir önek (prefix) yazmanız gerekmektedir. Modeli eğitirken ya da tahminleme yaparken “summarize:” şeklinde bir prefix yazdığınızda model artık bir özetleme yapacağını anlayacaktır. Bu şekilde model istenilen herhangi bir işleve uyandırılabilir. Ön eğitilmiş gelen T5 modelini kendi verilerimiz üzerinde ince ayar yaparak da kullanabilmekteyiz. Yaptığımız çalışmada T5 modeli soru cevap sistemi için uygun bir hale


getirilmiştir. Elimizde bulunan SQuAD 1.1 tipindeki veri seti T5 modelinin anlayabileceği bir formatta değildir. Aşağıda gösterildiği gibi uygun bir yapıya dönüştürülmüştür.

```
input_text = f"question: {question} context: {context}"
output_text = "answer"
```

Bu yapıya baktığımızda modelin hangi görevi yapacağını anlaması için örnek ifadesi olarak “question” yazılmıştır. Bu ifadeyi gören model bir soru cevap yapacağını anlamaktadır.


2.3. BART (Bidirectional and Auto-Regressive Transformer)

BART modeli de T5 modelinde olduğu gibi encoder-decoder yapısından oluşmaktadır. Yine bir diziden başka bir diziye dönüştürme işini yapmaktadır. Encoder yapısında BERT modelindeki gibi çift yönlü kodlayıcı kullanırken decoder yapısında ise GPT modellerinin temel özelliğini oluşturan otoregresif bir kod çözücü kullanılmaktadır. BART modeli ön eğitim aşamasında bozulmuş veriden orijinal veriyi yeniden yapılandırmayı öğrenir. Eğitim aşamasında maskeleye ya da gürültü ekleyerek veriler bozulur. Model bu haliyle eğitilerek bozulmuş verilerden gerçek veriyi bulmayı öğrenir [9]. T5 modeli ile arasındaki en büyük fark olarak bu durum görülmektedir. Bu tarz bir yaklaşım BART modelini metin özetleme, metin oluşturma gibi görevlerde daha performanslı yapmaktadır.



Şekil 3: BART Modeli Gürültü Ekleme [9]

Şekil 3’e baktığımızda BART modeli maskeleye, silme, cümle permütasyonu, cümle döndürme metin doldurma gibi yöntemler kullanarak gürültü ekleme işlemlerini yapmaktadır. Model bu şekilde ön eğitimli olarak gelmektedir.



Şekil 4: BART Model Mimarisi [9]

Şekil 4’e baktığımızda modelin bir encoder-decoder yapısından oluştuğu görülmektedir. Bu model sınıflandırma görevlerinde kullanılabileceği gibi diziden diziye görevlerde de kullanılabilmektedir. Yaptığımız çalışmada model bir soru-cevap görevi için uygun bir yapıya dönüştürülmüştür. T5 modelinde olduğu gibi bir örnek kullanma gereği yoktur. Modele ince ayar yapıldığı aşamada, eldeki veri setinden hangi işi yapması gerektiğine uyum sağlayabilmektedir.

3. Deney

SQuAD 1.1. tipinde bir veri seti kullanılarak soru cevap sistemi üzerinde bir eğitim yapılmıştır. SQuAD 1.1 veri kümesi içerisinde “question”, “context” ve “answer” gibi yapıları barındırmaktadır. BERT modelleri için veri seti formatı mevcut haliyle sorun oluşturmamaktadır. Fakat T5 ve BART gibi modeller için veri seti formatı uygun hale getirilmiştir. Veri seti hazırlandıktan sonra seçilen modellere ince ayar yapılmıştır.

3.1. Veri Seti


Veri seti olarak SQuAD 1.1 tipinde tarih ve genel kültür verilerinden oluşan Türkçe bir derlem kullanılmıştır. Derlemde toplam 9198 adet soru-cevap çifti bulunmaktadır. Veri seti bir derlem (context), bu derlem ile alakalı soru, sorunun derlem içerisindeki başlangıç konumunu ve cevabını içeren bir yapıdan oluşmaktadır. Bu haliyle veri seti BERT modellerinin ince ayar yapılandırılmasında sorunsuz bir şekilde kullanılabilir. Fakat T5 ve BART gibi modeller için veri seti yapısının değişmesi gerekmektedir. T5 ve BART modeline uygun olarak veri setinin formatı da değiştirilmiştir. Bu veri seti formatları Şekil 5 ve Şekil 6’da verilmiştir.

	context	question	answer
0	İslam dünyasında bilimin 16. yüzyılda hala yük...	el-Hasan b. Muhammed el-Vezzan isimli bilgin a...	Afrikalı Leo
1	İslam dünyasında bilimin 16. yüzyılda hala yük...	el-Hasan b. Muhammed el-Vezzan hangi şehirde b...	Fas (Fez) şehrinde
2	İslam dünyasında bilimin 16. yüzyılda hala yük...	el-Hasan b. Muhammed el-Vezzan sicilyalı korsa... ilk olarak Napoli'ye daha sonra Roma'ya	
3	İslam dünyasında bilimin 16. yüzyılda hala yük...	el-Hasan b. Muhammed el-Vezzan kim tarafından ...	Papa X. Leo
4	İslam dünyasında bilimin 16. yüzyılda hala yük...	el-Hasan b. Muhammed el-Vezzan kaç yılında vaf...	6.1.1520 yılında


Şekil 5: T5 ve BART dil modellerine ait veri seti yapısı

context	question	answer
İslam dünyasında bilimin 16. yüzyılda hala ...	el-Hasan b. Muhammed el-Vezzan isimli bilgin avrupa'da nasıl tanınmaktadır ?	{ 'answer_start': '171', 'text': 'Afrikalı Leo' }
İslam dünyasında bilimin 16. yüzyılda hala ...	el-Hasan b. Muhammed el-Vezzan hangi şehirde büyümüştür ?	{ 'answer_start': '278', 'text': 'Fas (Fez) şehrinde' }
İslam dünyasında bilimin 16. yüzyılda hala ...	el-Hasan b. Muhammed el-Vezzan sicilyalı ko...	{ 'answer_start': '587', 'text': 'İlk olarak Napoli'ye daha sonra Roma'ya' }
İslam dünyasında bilimin 16. yüzyılda hala ...	el-Hasan b. Muhammed el-Vezzan kim tarafından vafiz edilmiştir ?	{ 'answer_start': '635', 'text': 'Papa X. Leo' }
İslam dünyasında bilimin 16. yüzyılda hala ...	el-Hasan b. Muhammed el-Vezzan kaç yılında vafiz edilmiştir ?	{ 'answer_start': '658', 'text': '6.1.1520 yılında' }

Şekil 6: BERT ve BERT tabanlı dil modellerine ait veri seti yapısı



Şekil 7: Cevap Uzunluk Dağılımı



Şekil 8: Başlangıç Pozisyonu Dağılımı

Şekil 7 ve 8’e baktığımızda veri setinin dağılımı ile ilgili bilgiler sunulmuştur. Veri seti genelde kısa cevaplı verilerden oluşmaktadır. Ayrıca cevapların pozisyonlarına bakıldığında genellikle metnin başında bulunduğu görülmektedir.

3.2. İnce Ayar Aşaması

BERT, T5 ve BART gibi modeller ön eğitilmiş modellerdir. Bu modelleri kendi veri setlerimizi üzerinde ince ayar yapabiliriz. Bu sayede model belli bir amaç doğrultusunda özelleşecektir. Elimizdeki veri seti kullanılarak 3 farklı tipteki model için ince ayar işlemi gerçekleştirilmiştir. Bu işlemler için Google Colab’ın sunduğu A100 tipindeki GPU’lardan yararlanılmıştır. Bu gibi büyük dil modelleri bellekte büyük bir yer kaplamaktadır. Örneğin mBART ve mT5 modelleri ortalama 2.4 GB gibi bir alan işgal etmektedir. Ayrıca milyarı bulan parametre sayılarına bakıldığında modelin eğitimi için Google’ın sunduğu GPU hizmetinden yararlanılmıştır. Yaptığımız çalışmada “bert-base-uncased”, “bert-base-turkish-cased”, “distilbert-base-multilingual-cased”, “mt5-base”, “mBart-large-50” gibi farklı türden modellerin soru cevap sistemi üzerindeki performansı değerlendirilmiştir. Modeller baktığımızda çoğu modelin çok dil desteği olmasına özen gösterilmiştir. Ayrıca “bert-base-uncased” modelini kullanarak Türkçe üzerindeki başarımına da bakılmıştır. İnce ayar ile aslında yapılan şey hazır olarak gelen ön eğitilmiş bir modelin bazı katmanları dondurularak kendi verilerimiz ile yeniden eğitilmesidir. Burada yaygın olarak kullanılan strateji ilk önce son katman hariç bütün katmanların dondurularak, modelin kendi veri setimiz ile eğitilmesidir. Bu şekilde modelin daha önce öğrendiği bilgileri (ağırlıkları) unutmasını sağlıyoruz. Daha sonra ise tüm katmanları açıp epoch sayısı çok az olacak şekilde modeli tekrar eğitiyoruz. Aslında son bir ayar çekiyoruz. İşte bu son kısımda yapılan iş, ince ayar olarak bilinmektedir. mBart ve mT5 gibi modelleri ince ayar yaparken modelin yapısı gereği giriş formatı değiştirilmiştir. Bu modellerin Transformer mimarisinin iki yapısını kullandığını, BERT ve BERT tabanlı modellerin ise Transformer mimarisinin sadece encoder yapısını kullandığını ifade etmiştik. Soru-cevap sistemlerinde hangi mimarinin başarılı olduğunu tespit etmek amacıyla modellerimize ince ayar işlemi gerçekleştiriyoruz.

4. Sonuçlar ve Tartışma

SQuAD veri kümesi üzerinde 5 farklı dil modeli için deneysel çalışmalar gerçekleştirilmiştir. Çalışma sonuçları Çizelge 1’de verilmiştir. EM skor; sorulan bir sorunun tahmin edilen cevap ile gerçek cevap arasındaki birerbir eşleşmeyi göstermektedir. Bu bakımdan EM skor çok katı bir değerlendirme ölçütü olarak ifade edilir. F1-skor; tahmin ve gerçek değer arasındaki precision ve recal’in harmonik ortalaması alınarak bir skor üretilir. Eğer tahmin ve gerçek değer birbirine eşitse F1-skor 1 olur. Eğer tahmin ve gerçek değer boşsa ya da ortak kelimeler yoksa F1 skor 0 olarak kabul edilir. Aksi takdirde precision ve recall kullanılarak F1-skor hesaplanmaktadır. Rouge-1; kelime düzeyinde (unigram) örtüşmedir. Doğru kelimelerin ne kadarının model çıktısında olduğunu ölçer. Rouge-2 ise iki kelimelik grupların örtüşmesini (bigram) ifade eder. Doğru kelime sıralamalarının ne kadarının model çıktısında olduğunu değerlendirir. Son olarak Rouge-L’de en uzun ortak alt diziyi (LCS - Longest Common Subsequence) kullanarak örtüşmeyi ölçer. Bu metrik, iki dize arasında sıralı bir şekilde en uzun ortak diziyi bulmaktadır.

Çizelge 1: İnce Ayar Yapılmış Modellerin Sonuçları

Model	EM	F1	Rouge-1	Rouge-2	Rouge-L
mBart	0.51	0.77	0.80	0.60	0.80
mT5	0.45	0.67	0.71	0.53	0.71
bert-turk	0.34	0.65	0.87	0.69	0.87
Distilbert multi	0.17	0.37	0.49	0.37	0.49
bert-base	0.04	0.11	0.26	0.13	0.26

Çizelge 1 incelendiğinde çok dil desteği olan mBart modelinin en yüksek skor değeri ürettiği görülmektedir. Yine çoklu dil desteği olmayan bert-base modeli ise en düşük skor değerini üretmiştir. Çok dil desteği olan modeller Türkçe dahil birçok dil ile eğitilmiştir. Bu kapsamdan bakıldığında multilingual olan modeller Türkçe üzerinde daha başarılı sonuçlar vermiştir. Bunun yanı sıra yukarıdaki modeller iki farklı mimariden oluşmaktadır. BART ile T5 encoder-decoder mimarisi kullanırken geri kalan bert-base, bert-turk ve distilbert ise sadece encoder mimarisinden oluşmaktadır. Mimari açısından sonuçları değerlendirdiğimizde encoder-decoder mimarisi destekleyen mBart ve mT5 gibi modellerin daha başarılı sonuçlar verdiği gözlemlenmiştir. bert-turk modeli ise sadece Türkçe veriler ile eğitilmesine rağmen skor olarak mBart ve mT5’in gerisinde kalmıştır. Burada özellikle bert-turk modeli EM ve F1-skoru bakımından düşük ama Rouge skorları açısından yüksek değerler üretmiştir. F1-skorunun anlamsal ilişkiyi yakalaması bakımından daha doğru sonuçlar verdiği bilinmektedir. bert-turk modeli cevabı içeren kelimeleri barındırdığı için Rouge skorları bakımından yüksek çıkmıştır. Çünkü Rouge n-gram temelinde kelime ya da cümlelere bakılmaktadır. Fakat EM metriği bakımından çok iyi bir performans gösterememiştir. Bunu şöyle açıklayabiliriz. Örneğin gerçek cevap “Osmanlı İmparatorluğu” fakat model “Osmanlı Devleti” şeklinde bir cevap verdiğinde Rouge-1 skoru yüksek olurken EM skoru düşük olacaktır. bert-turk’e F1-skoru açısından baktığımızda ise neredeyse mT5 ile yakın bir değer

üretmiştir. mT5 modeli sadece daha iyi gerçek eşleşmeler sağlamıştır.

Yaptığımız çalışma ve değerlendirme sonuçlarına baktığımızda soru-cevap sistemleri için BART ve T5 gibi modellerin daha iyi sonuçlar verdiği gözlemlenmiştir. Bunun yanında Transformer mimarisinin sadece decoder yapısını içeren üretken olarak adlandırdığımız GPT, Llama ve Mistral gibi modeller de soru cevap sistemi için denenmiştir. Fakat bu yapılar sürekli üretken bir cevap verme eğiliminde oldukları için çalışmada kullanılan modellere göre daha düşük performans göstermişlerdir.

Sonuç olarak büyük dil modelleri ile Türkçe bir veri seti üzerinden ince ayar işlemi gerçekleştirilmiştir. Yapıların Türkçe verileri üzerindeki başarımı karşılaştırılmıştır. Burada kullanılan veri setinin az olması nedeni ile modeller belli bir ölçüde başarımlar göstermiştir. İleriye dönük çalışmalarda veri setinin boyutu ve veri türü ve sayısı artırılarak hem modellerin performanslarının daha da artması hem de farklı türden konular için soru cevaplama sistemleri geliştirmek hedeflenmektedir.

5. Kaynaklar

- [1] N. Abadani, J. Mozafari, A. Fatemi, M. A. Nematbakhsh, and A. Kazemi, "ParSQuAD: Machine Translated SQuAD dataset for Persian Question Answering," in *2021 7th International Conference on Web Research, ICWR 2021*, Institute of Electrical and Electronics Engineers Inc., May 2021.
- [2] E. Dogan *et al.*, "Türkçe Dil Modellerinin Performans Karşılaştırması, Performance Comparison of Turkish Language Models," Apr. 2024.
- [3] M. Çetiner, A. Yıldırım, C. Öksüz, and B. Onay, "Mevzuat Verisinde Soru Cevaplama Uygulaması Question Answering Application on Legalisation Dataset," in *Proceedings - 6th International Conference on Computer Science and Engineering, UBMK 2021*, Institute of Electrical and Electronics Engineers Inc., 2021.
- [4] L. Engländer, H. Sterz, C. Poth, J. Pfeiffer, I. Kuznetsov, and I. Gurevych, "M2QA: Multi-domain Multilingual Question Answering," Jul. 2024.
- [5] E. Budur, R. Özçelik, D. Soylu, O. Khatat, T. Güngör, and C. Potts, "Building Efficient and Effective OpenQA Systems for Low-Resource Languages," Jan. 2024.
- [6] F. Soygazi, O. Çiftçi, U. Kök, and S. Cengiz, "THQuAD: Turkish Historic Question Answering Dataset for Reading Comprehension," in *Proceedings - 6th International Conference on Computer Science and Engineering, UBMK 2021*, Institute of Electrical and Electronics Engineers Inc., 2021.
- [7] J. Devlin, M.-W. Chang, K. Lee, K. T. Google, and A. I. Language, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," May 2019.
- [8] C. Raffel *et al.*, "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," Oct. 2019.
- [9] M. Lewis *et al.*, "BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension," Oct. 2019.